BÁO CÁO ĐỒ ÁN

MÔN: TRUY XUẤT THÔNG TIN – CS419.N21

ĐỀ TÀI:

Mô hình Vector Space và Latent Semantic Index (LSI)

Sinh viên thực hiện: Nguyễn Tam Điệp

MSSV: 19521360

Giảng viên hướng dẫn: Nguyễn Trọng Chỉnh

TP.HCM, tháng 7, năm 2023

Mục lục

1. Mô hình Vector Space 2
1.1. Giới thiệu mô hình 2
1.2. Chọn term 2
1.3. Công thức tính trọng số term 5
1.4. Lập chỉ mục 6
1.5. Xử lý truy vấn 8
1.6. Đánh giá 9
2. Mô hình Latent Semantic Index 9
2.1. Giới thiệu mô hình 9
2.2. Chọn term 11
2.3. Các bước xử lý sau khi chọn term 11
2.4. Xử lý truy vấn 13
2.5. Đánh giá 13

1. Mô hình Vector Space

1.1. Giới thiệu mô hình

Đặc điểm của mô hình vector space:

- Các tài liệu được biểu diễn dưới dạng “bag of words”.

- Tài liệu được tính toán như một vector với các đặc điểm của nó:

  + Tài liệu là một mảng số thực giống như một vector nhiều chiều.

  + Mỗi term là một chiều trong không gian. (các vector thường thưa)

  + Tính toán dựa trên hướng và độ lớn.

- Truy vấn được biểu diễn bằng một vector cùng không gian với tài liệu

- Tính toán giữa truy vấn và tài liệu dựa trên chiều dài và hướng của vector tương ứng của chúng.

- Khoảng cách giữa hai vector tài liệu và truy vấn được xem là độ tương đồng giữa tài liệu và truy vấn. Khoảng cách này được dung để xếp hạng tài liệu.

Trong báo cáo này, em trình bày việc thử nghiệm mô hình Vector Space trên bộ tài liệu Cranfield, gồm 1400 tài liệu và 225 câu truy vấn.

1.2. Chọn term

- Với mỗi tài liệu trong tập tài liệu Cranfield, thực hiện việc tách câu.

Ví dụ một tài liệu trong tập tài liệu Cranfield:

```
'experimental investigation of the aerodynamics of a wing in a slipstream
. an experimental study of a wing in a propeller slipstream was made in
order to determine the spanwise distribution of the lift increase due
to slipstream at different angles of attack of the wing and at different
free stream to slipstream velocity ratios .  the results were intended
in part as an evaluation basis for different theoretical treatments of
this problem . the comparative span loading curves, together with
supporting evidence, showed that a substantial part of the lift increment
produced by the slipstream was due to a /destalling/ or boundary layer
control effect .  the integrated remaining lift increment, after
subtracting this destalling lift, was found to agree well with a
potential flow theory . an empirical evaluation of the destalling effects
was made for the specific configuration of the experiment .'
```

```
['experimental investigation of the aerodynamics of a wing in a slipstream .', 'an experimental study of a wing in a propeller slipstream was made in order to determine the spanwise distribution of the lift increase due to slipstream at different angles of attack of the wing and at different free stream to slipstream velocity ratios .', 'the results were intended in part as an evaluation basis for different theoretical treatments of this problem .', 'the comparative span loading curves, together with supporting evidence, showed that a substantial part of the lift increment produced by the slipstream was due to a /destalling/ or boundary layer control effect .', 'the integrated remaining lift increment, after subtracting this destalling lift, was found to agree well with a potential flow theory .', 'an empirical evaluation of the destalling effects was made for the specific configuration of the experiment .']
```

- Sau đó, với mỗi câu, tiến hành tách từ:

Ví dụ:

```
'experimental investigation of the aerodynamics of a wing in a slipstream .'
```

```
['experimental', 'investigation', 'of', 'the', 'aerodynamics', 'of', 'a', 'wing', 'in', 'a', 'slipstream', '.']
```

- Thực hiện loại bỏ các dấu câu (['.', ',', ':', '`', '"', "'", '!', '?', "``", "''"])

Ví dụ:

```
['the', 'comparative', 'span', 'loading', 'curves', ',', 'together', 'with', 'supporting', 'evidence', ',', 'showed', 'that', 'a', 'substantial', 'part', 'of', 'the', 'lift', 'increment', 'produced', 'by', 'the', 'slipstream', 'was', 'due', 'to', 'a', '/destalling/', 'or', 'boundary', 'layer', 'control', 'effect', '.']
```

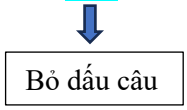

- Loại bỏ các ký tự số:

```
['experiments', 'were', 'performed', 'in', 'the', '12', 'in']
```

Loại bỏ ký tự số

- Loại bỏ các từ là stopword

Sử dụng danh sách các stopword của thư viện nltk:

```
['i', 'me', 'my', 'myself', 'we', 'our', 'ours', 'ourselves', 'you',
"you're", "you've", "you'll", "you'd", 'your', 'yours', 'yourself',
'yourselves', 'he', 'him', 'his', 'himself', 'she', "she's", 'her',
'hers', 'herself', 'it', "it's", 'its', 'itself', 'they', 'them',
'their', 'theirs', 'themselves', 'what', 'which', 'who', 'whom', 'this',
'that', "that'll", 'these', 'those', 'am', 'is', 'are', 'was', 'were',
'be', 'been', 'being', 'have', 'has', 'had', 'having', 'do', 'does',
'did', 'doing', 'a', 'an', 'the', 'and', 'but', 'if', 'or', 'because',
'as', 'until', 'while', 'of', 'at', 'by', 'for', 'with', 'about',
'against', 'between', 'into', 'through', 'during', 'before', 'after',
'above', 'below', 'to', 'from', 'up', 'down', 'in', 'out', 'on', 'off',
'over', 'under', 'again', 'further', 'then', 'once', 'here', 'there',
'when', 'where', 'why', 'how', 'all', 'any', 'both', 'each', 'few',
'more', 'most', 'other', 'some', 'such', 'no', 'nor', 'not', 'only',
'own', 'same', 'so', 'than', 'too', 'very', 's', 't', 'can', 'will',
'just', 'don', "don't", 'should', "should've", 'now', 'd', 'll', 'm',
'o', 're', 've', 'y', 'ain', 'aren', "aren't", 'couldn', "couldn't",
'didn', "didn't", 'doesn', "doesn't", 'hadn', "hadn't", 'hasn',
"hasn't", 'haven', "haven't", 'isn', "isn't", 'ma', 'mightn',
"mightn't", 'mustn', "mustn't", 'needn', "needn't", 'shan', "shan't",
'shouldn', "shouldn't", 'wasn', "wasn't", 'weren', "weren't", 'won',
"won't", 'wouldn', "wouldn't", 'oh']
```

- Loại bỏ ký tự dấu câu, ký tự chữ số bị dính liền vào mỗi từ

Ví dụ:

```
['the', 'comparative', 'span', 'loading', 'curves', ',', 'together',
'with', 'supporting', 'evidence', ',', 'showed', 'that', 'a',
'substantial', 'part', 'of', 'the', 'lift', 'increment', 'produced',
```

```
'by', 'the', 'slipstream', 'was', 'due', 'to', 'a', '/destalling/',
'or', 'boundary', 'layer', 'control', 'effect']
```

destalling

```
['the', 'results', 'of', 'the', 'investigation', 'on', 'representative',
'blunt', 'bodies', 'at', 'hypersonic', 'mach', 'numbers', 'and',
'nozzle', 'stagnation', 'temperatures', 'up', 'to', 'approximately',
'6000degreek', 'are', 'presented']
```

degreek

1.3. Công thức tính trọng số term

- Trọng số của term t trong tài liệu có DocID = d được tính theo công thức sau:

$w_{t,d} = tf_{t,d} * \mathrm{idf}_{t,d}$ với:

$tf_{t,d} = \text{số lần xuất hiện của term } t \text{ trong tài liệu có } DocID = d$

$idf_t = \ln \frac{N}{nDoc_t}$ (tính theo logarith cơ số e)

(N là số lượng tài liệu trong tập tài liệu, ví dụ trong tập tài liệu Cranfield thì N=1400,

$nDoc_t$ là số tài liệu chứa term t trong tập tài liệu)

Ví dụ, cho tài liệu với N = 1400, DocID=1 và biết $nDoc_{experiment} = 339$ dưới đây:

```
['experiment', 'investig', 'aerodynam', 'wing', 'slipstream',
'experiment', 'studi', 'wing', 'propel', 'slipstream', 'made', 'order',
'determin', 'spanwis', 'distribut', 'lift', 'increas', 'due',
'slipstream', 'differ', 'angl', 'attack', 'wing', 'differ', 'free',
'stream', 'slipstream', 'veloc', 'ratio', 'result', 'intend', 'part',
'evalu', 'basi', 'differ', 'theoret', 'treatment', 'problem', 'compar',
'span', 'load', 'curv', 'togeth', 'support', 'evid', 'show',
'substanti', 'part', 'lift', 'increment', 'produc', 'slipstream', 'due',
'destal', 'boundari', 'layer', 'control', 'effect', 'integr', 'remain',
'lift', 'increment', 'subtract', 'destal', 'lift', 'found', 'agre',
'well', 'potenti', 'flow', 'theori', 'empir', 'evalu', 'destal',
'effect', 'made', 'specif', 'configur', 'experi']
```

Ta tính được :

$$tf_{\text{experiment},1} = 2$$

$$idf_{\text{experiment}} = \ln \frac{1400}{339} = 1.42$$

Do đó: $w_{\text{experiment},1} = 2 * 1.42 = 2.84$

- Tiến hành chuẩn hóa trọng số:

$$W_{t,d} = \frac{w_{t,d}}{norm(w_d)}$$

Với:

$$norm(w_d) = \sqrt{w_{t_1,d}^2 + w_{t_2,d}^2 + \cdots + w_{t_m,d}^2}$$

$t_1, t_2, \ldots, t_m$ là các term của tài liệu có DocID = d

1.4. Lập chỉ mục

Chỉ mục gồm từ điển và posting list

Từ điển chứa các thông tin: $term, nDoc_{term}, idf_{term}$, con trỏ tới posting list.

Posting list là danh sách các tài liệu, chứa các thông tin: $DocID, tf, weight$.

Cấu trúc chỉ mục:

$$\{term: [\, nDoc_{term}, idf_{term}, [\, [DocID, tf_{term,DocID}, weight], \ldots \,] \,], \ldots\}$$

($weight$ là trọng số đã chuẩn hóa)

Các bước lập chỉ mục:

- Từ tập tài liệu đã cho, tạo bảng termtable, mỗi hàng của bảng bao gồm term và DocID của tài liệu chứa term:

Tài liệu 1: term_b, term_a, term_c

Tài liệu 2: term_c, term_b

Tài liệu 3: term_b, term_c, term_b

term	DocID
term_b	1
term_a	1
term_c	1
term_c	2
term_b	2
term_b	3
term_c	3
term_b	3

- Sắp xếp lại termtable theo thứ tự từ điển của term:

term	DocID
term_a	1
term_b	1
term_b	2
term_b	3
term_b	3
term_c	1
term_c	2
term_c	3

- Từ bảng termtable, tạo bảng termfreqtable, mỗi hàng của termfreqtable bao gồm $term, DocID, tf_{term}$

term	DocID	tf
term_a	1	1
term_b	1	1
term_b	2	1
term_b	3	2
term_c	1	1
term_c	2	1
term_c	3	1

- Tạo từ điển gồm term, nDoc, idf, posting list (posting list gồm DocID, tf, weight) với giá trị khởi tạo: idf = 0, weight=0

```
{
term_a: 1, 0,  [1, 1, 0],
term_b: 3, 0, [[1, 1, 0], [2, 1, 0], [3, 2, 0]],
term_c: 3, 0, [[1, 1, 0], [2, 1, 0], [3, 1, 0]]
}
```

Sử dụng công thức tính trọng số term (đã trình bày ở mục 1.3) để tính idf và weight:

```
{
term_a: 1, 1.1,  [1, 1, 1.1],
term_b: 3, 0, [[1, 1, 0], [2, 1, 0], [3, 2, 0]],
term_c: 3, 0, [[1, 1, 0], [2, 1, 0], [3, 1, 0]]
}
```

1.5. Xử lý truy vấn

- Cách chọn term của câu truy vấn giống như cách chọn term của tài liệu, cũng bao gồm các bước loại bỏ dấu câu, ký tự số, stopword. Các từ trong truy vấn cũng được stemming.

- Dựa vào chỉ mục đã lập, tìm DocID của mỗi term trong truy vấn:

q:	term_jhv,	term_xak,	term_mvc,	term_lkf,	term_lza,	term_okl,	term_jhv
	⬇	⬇	⬇	⬇	⬇	⬇	⬇
DocID	2	1	3	1	2	3	2

- Tính trọng số của các term trong truy vấn:

q:	term_jhv,	term_xak,	term_mvc,	term_lkf,	term_lza,	term_okl
query_weight	2	1	1	1	1	1
chuẩn hóa	0.67	0.33	0.33	0.33	0.33	0.33

- Kết quả của truy vấn là một danh sách gồm DocID và độ tương đồng giữa truy vấn với tài liệu được tính bằng giá trị weight score.

$$R = [(doc1, WeightScore_{doc1}), (doc2, WeighScore_{doc2}), \dots]$$

$$WeightScore_d = \sum_{term\ có\ DocID\ là\ d} query\ W_{term} * W_{term}$$

Với $queryW_{term}$ là trọng số (đã chuẩn hóa) của $term$ có DocID = d trong truy vấn, W_{term} là trọng số của term ứng với DocID = d trong chỉ mục.

Ví dụ:

term in q: term_xak, term_lkf, term_jhv, term_lza, term_mvc, term_okl

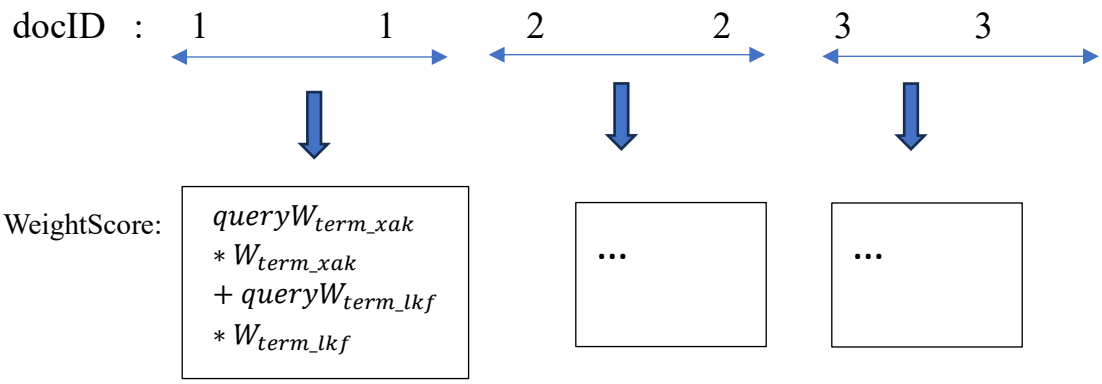

1.6. Đánh giá

Thử nghiệm mô hình vector space trên bộ dữ liệu Cranfield, thu được kết quả(kết quả đã làm tròn đến chữ số thập phân thứ 2):

Recall	95.24%
Precision	0.996%
MAP	37.54 %

(Recall là giá trị Recall trung bình của 225 câu truy vấn. Precision là giá trị Precision của 225 câu truy vấn. MAP là giá trị MAP nội suy 11 điểm của TREC)

2. Mô hình Latent Semantic Index

2.1. Giới thiệu mô hình

Mô hình LSI (Latent Semantic Index) được đề xuất nhằm:

- Đảm bảo các chiều trong không gian là độc lập.

- Các chiều được chọn mang ý nghĩa của những từ khoá dựa trên sự xuất hiện đồng thời của chúng.

Không nhất thiết phải là tập từ khóa sử dụng trong các tài liệu (ngữ nghĩa tiềm ẩn).

- Có thể giảm số chiều trong không gian mà cho kết quả xấp xỉ.

Cơ sở toán:

Cho ma trận A, vector x được gọi lag vector riêng của A nếu tồn tại một số λ, gọi là trị riêng sao cho:

$$\mathrm{Ax} = \lambda \mathrm{x}$$

→ x là vector riêng của A thì x không thay đổi phương khi nhân với A.

→ Gủa sử $\mathrm{x}_1, x_2, x_3, \dots, x_n$ là vector riêng tương ứng với các trị riêng λ khác nhau của A, khi đó, x_i và x_j (i ≠ j) độc lập tuyến tính.

Cho ma trận A, giả sử $\sigma_1^2 \geq \sigma_2^2 \geq \sigma_3^2 \dots \geq \sigma_n^2$ là các trị riêng của $\mathrm{A}^{\mathrm{T}}A$ tương ứng với các vector riêng $\mathrm{x}_1, x_2, x_3, \dots x_n$

Đặt $\mathrm{U} = \{\mathrm{x}_1, x_2, x_3, \dots, x_n\}$

$\mathrm{y}_i = \dfrac{\mathrm{Ax}_i}{\sigma_i}$ $(i = 0 \dots n)$

$\mathrm{S} = \{\mathrm{y}_1, y_2, y_3, \dots, y_n\}$

Σ là ma trận đường chéo trong đó các giá trị trên đường chéo là $\sigma_1, \sigma_2, \sigma_3, \dots, \sigma_n$

Khi đó $\mathrm{A} = \mathrm{S}\Sigma\mathrm{U}^{\mathrm{T}}$

Được gọi là một phép tách ma trận SVD (Singular Value Decomposition)

Trong trường hợp chỉ chọn r giá trị riêng đầu tiêng (r<<n)

Đặt $\mathrm{U}_r = \{x_1, x_2, x_3, \dots, x_r\}$

$\mathrm{y}_i = \dfrac{\mathrm{Ax}_i}{\sigma_i}$ $(i = 0 \dots r)$

$S_r = \{y_1, y_2, y_3, \dots y_r\}$

Σ là ma trận đường chéo trong đó các giá trị trên đường chéo là $\sigma_1, \sigma_2, \sigma_3, \dots, \sigma_r$

Khi đó $\mathrm{A} \approx \mathrm{S_r}\Sigma U_r^T$

Latent Semantic Index:

Áp dụng phép tách ma trận SVD cho ma trận A là ma trận Term-Document:

$$A = S\Sigma U^T$$

Khi đó, ma trận vector từ khóa K và ma trận vector tài liệu D sẽ được biểu diễn trong cùng không gian với các chiều là các vector riêng qua phép biến đổi:

$$K = S\Sigma$$

$$D = \Sigma U^T$$

Các vector riêng được xem là những nghĩa tiềm ẩn trong mối liên hệ cùng xuất hiện của các từ khóa

Trong trường hợp muốn giảm số chiều, sẽ chọn r trị riêng và vector riêng đầu tiên, khi đó:

$$K = S_r \Sigma_r$$

$$D = \Sigma_r U_r^T$$

Trong báo cáo này, em trình bày việc thử nghiệm mô hình LSI trên tập tài liệu Cranfield.

2.2. Chọn term

Cách chọn term trong mô hình LSI cũng giống với cách chọn term trong mô hình Vector Space. Ta cũng tiến hành loại bỏ ký tự chữ số, dấu câu, loại bỏ stoword. Các term cũng được stemming.

2.3. Các bước xử lý sau khi chọn term

- Từ tập tài liệu Cranfield, tạo ma trận Term-Document A

	doc1	doc2	doc3	doc4 …
term1	20	30	…	…
term2	12	50	…	…
term3	33	11	…	…

…

Ma trận A có kích thước 4407 x 1400

- Áp dụng phép tách ma trận SVD cho ma trận Term-Document A:

$$A = S\Sigma U^T$$

Trong bước này, sử dụng thư hàm `svd` của thư viện `numpy.linalg`, ta được

ma trận S có kích thước 4407 x 4407

ma trận Σ có kích thước 1400 x 1400

ma trận U^T có kích thước 1400 x 1400

Giảm kích thước S, Σ, U^T: chọn r = 700, ta có:

ma trận S_2 có kích thước 4407 x 700

ma trận Σ_2 có kích thươc 700 x 700

ma trận U_2^T có kích thước 700 x 1400

- Tính ma trận vector từ khóa K và ma trận vector tài liệu D:

$K = S_2 \cdot \Sigma_2$

$D = \Sigma_2 \cdot U_2^T$

- Ví dụ:

Ma trận K:

-0.12 0.21 … → vector của term1

-0.23 0.11 … → vector của term2

-0.22 -0.1 … → vector của term3

…. …. …. → …

Ma trận D:

-0.71	-0.93	-1.35	…
0.72	1.08	0.4	…
1.01	1.43	1.41	…
…	…	…	
⬇	⬇	⬇	
doc1	doc2	doc3	

2.4. Xử lý truy vấn

Loại bỏ ký tự số, dấu câu, stopword và stemming term.

Tính vector truy vấn:

q: $\mathrm{term}_1, \mathrm{term}_2, \mathrm{term}_3, \dots, \mathrm{term}_\mathrm{n}$

$$V_q = \frac{V_{term_1} + V_{term_2} + V_{term_3} + \cdots + V_{term_n}}{n}$$

Với các vector $V_{term_1}, V_{term_2}, V_{term_3}, \dots, V_{term_n}$ được lấy ra từ ma trận vector từ khóa K.

- Tính độ tương đồng giữa truy vấn và tài liệu:

Tính theo $\cos(V_q, V_d)$

Với V_d được lấy ra từ ma trận vector tài liệu D

- Kết quả truy vấn là danh sách gồm có DocID của tài liệu và giá trị độ tương đồng

`[(DocID,` $\cos(V_q, V_d)$`), … ]`

- Sắp xếp lại danh sách kết quả trên theo thứ tự giảm dần của độ tương đồng.

- Từ danh sách đã sắp xếp, chọn lấy 300 tài liệu đầu tiên (tức 300 tài liệu có độ tương đồng cao nhất) là kết quả cuối cùng của truy vấn.

2.5. Đánh giá

Thử nghiệm với nhiều giá trị r để giảm kích thước $\mathrm{S}, \Sigma, \mathrm{U}^\mathrm{T}$ (tức trường hợp chỉ chọn r giá trị riêng đầu tiên), ta được kết quả (kết quả đã làm tròn đến chữ số thập phân thứ 2):

r	MAP	Recall	Precision
100	7.41 %	39.6%	1.07%
200	9.2%	48.71%	1.26%
300	9.54%	49.54%	1.3%
400	10.52%	59.53%	1.3%
500	10.43%	59.2%	1.59%
600	10.56%	59.3%	1.6%
700	10.61%	59.22%	1.6%
800	10.53%	59.19%	1.6%
900	10.5%	58.8%	1.6%
1000	10.58%	59.03%	1.6%

1100	10.57%	59.15%	1.6%

(Recall là giá trị Recall trung bình của 225 câu truy vấn. Precision là giá trị Precision của 225 câu truy vấn. MAP là giá trị MAP nội suy 11 điểm của TREC)