ĐẠI HỌC QUỐC GIA TP. HỒ CHÍ MINH

TRƯỜNG ĐẠI HỌC CÔNG NGHỆ THÔNG TIN

KHOA KHOA HỌC MÁY TÍNH

NGUYỄN TAM ĐIỆP - 19521360

ĐỒ ÁN MÔN HỌC XỬ LÝ ÂM THANH VÀ TIẾNG NÓI

CS337.O11

TỔNG HỢP TIẾNG NÓI – CHUYỂN ĐỔI VĂN BẢN TIẾNG ANH THÀNH TIẾNG NÓI SỬ DỤNG MÔ HÌNH TACOTRON 2

English Speech Synthesis Using Tacotron 2 Model

TP. HỒ CHÍ MINH, 2023

ĐẠI HỌC QUỐC GIA TP. HỒ CHÍ MINH

TRƯỜNG ĐẠI HỌC CÔNG NGHỆ THÔNG TIN

KHOA KHOA HỌC MÁY TÍNH

NGUYỄN TAM ĐIỆP – 19521360

ĐỒ ÁN MÔN HỌC XỬ LÝ ÂM THANH VÀ TIẾNG NÓI

CS337.O11

TỔNG HỢP TIẾNG NÓI – CHUYỂN ĐỔI VĂN BẢN TIẾNG ANH THÀNH TIẾNG NÓI SỬ DỤNG MÔ HÌNH TACOTRON 2

English Speech Synthesis Using Tacotron 2 Model

GIẢNG VIÊN HƯỚNG DẪN

TRỊNH QUỐC SƠN

TP. HỒ CHÍ MINH, 2023

Mục lục

1. MỤC TIÊU ĐỒ ÁN 4

2. CÁC NGHIÊN CỨU LIÊN QUAN 5

3. MÔ HÌNH TACOTRON 2 7

3.1. Kiến trúc chung của mô hình 7

3.2. Phần 1. Spectrogram Prediction Network 8

3.2.1. Quá trình Encoder 8

3.2.2. Quá trình Decoder 9

3.3. Phần 2. Vocoder 12

4. BỘ DỮ LIỆU SỬ DỤNG 14

5. HUẤN LUYỆN MÔ HÌNH 15

6. PHƯƠNG PHÁP ĐÁNH GIÁ KẾT QUẢ 16

7. THỬ NGHIỆM VỚI BỘ DỮ LIỆU LJ SPEECH 16

8. TÓM TẮT KẾT QUẢ ĐẠT ĐƯỢC 16

9. CÁC ĐIỂM HẠN CHẾ VÀ CÁC ĐIỂM CẦN CẢI TIẾN 22

DANH MỤC HÌNH VẼ

Hình 1. Mô tả bài toán 4
Hình 2. Kiến trúc chung của mô hình Tacotron 2 7
Hình 3. Kiến trúc mô hình Spectrogram Prediction Network 8
Hình 4. Mô hình Encoder 8
Hình 5. Mô hình Spectrogram Prediction Network chi tiết 11
Hình 6. Vocoder 12
Hình 7. Dữ liệu sử dụng 14
Hình 8. Dữ liệu huấn luyện 14
Hình 9. Huấn luyện mô hình Spectrogram Predict Network 15
Hình 10. WaveGlow 15

TÓM TẮT ĐỒ ÁN

Đò án này mô tả Tacotron 2, một kiến trúc mạng neuron nhân tạo cho tổng hợp giọng nói trực tiếp từ văn bản. Hệ thống bao gồm một mạng dự đoán đặc trưng recurrent sequence-to-sequence, ánh xạ các character embeddings thành mel-scale spectrograms, sau đó là một mô hình WaveNet được điều chỉnh hoạt động như một vocoder để tổng hợp time-domain waveforms từ các spectrogram đó. Mô hình của chúng tôi được huấn luyện trên bộ dữ liệu LJ Speech, đạt được điểm đánh giá Mean Opinion Score (MOS) là 4.5

MỞ ĐẦU

Tổng hợp tiếng nói, hay còn được gọi là chuyển văn bản thành giọng nói (Text To Speech, viết tắt là TTS), là quá trình tạo ra tiếng nói tự nhiên từ văn bản. Lĩnh vực này đã có những tiến bộ đáng kể trong những năm gần đây, nhằm tạo ra giọng nói tổng hợp mà không thể phân biệt được với giọng nói của con người.

Trong số các kỹ thuật được sử dụng trong TTS, Tacotron 2 đã trở thành một mô hình đáng chú ý. Tacotron 2 là một kiến trúc mạng nơ-ron kết hợp giữa mạng dự đoán đặc trưng từng chuỗi (sequence-to-sequence) với một bộ vocoder WaveNet được chỉnh sửa để tổng hợp giọng nói trực tiếp từ văn bản.

Mô hình Tacotron 2 bao gồm hai thành phần chính. Thành phần đầu tiên là một mạng recurrent sequence-to-sequence với cơ chế attention, biến đổi các chuỗi ký tự đầu vào thành mel-scale spectrograms. Những spectrograms này thu thập các đặc trưng âm học cần thiết để tạo ra giọng nói. Thành phần thứ hai là một phiên bản được chỉnh sửa của WaveNet, một mô hình sinh tổng quát biến đổi những spectrograms đã dự đoán thành sóng âm trong miền thời gian.

Điểm đặc biệt của Tacotron 2 là khả năng học trực tiếp từ dữ liệu mà không cần phụ thuộc vào chuyên môn hay hệ thống phân tích phức tạp. Bằng cách huấn luyện với các chuỗi ký tự đã được chuẩn hóa và waveforms giọng nói tương ứng, Tacotron 2 học cách tạo ra giọng nói tự nhiên chất lượng cao.

Nhiều đánh giá đã được tiến hành để đánh giá hiệu suất của Tacotron 2. Nó đã đạt được các kết quả ấn tượng, với điểm trung bình MOS (Mean Opinion Score) tương đương với âm thanh được ghi lại chuyên nghiệp. Tuy nhiên, vẫn còn khả năng cải thiện, vì một số lỗi trong phát âm của hệ thống đã khiến một số người đánh giá có sự ưu tiên hơn cho việc ghi âm thực tế.

Tacotron 2 cũng đã được thử nghiệm trên các văn bản nằm ngoài lĩnh vực, chứng tỏ khả năng tổng hợp âm của nó mở rộng sang các lĩnh vực khác nhau. Nó đạt được MOS cao khi tổng hợp thông tin từ những đề mục tin tức, cho thấy khả năng xử lý văn bản từ nhiều nguồn dữ liệu.

Các nghiên cứu về mô hình Tacotron 2 đã phân tích các thành phần của nó. So sánh đã được thực hiện giữa việc huấn luyện WaveNet với các mel spectrograms đã được dự đoán và thông qua mel spectrograms của đúng. Kết quả cho thấy hiệu suất tốt nhất được đạt khi các điều kiện huấn luyện và triển khai trùng khớp. Ngoài ra, đã thử nghiệm so sánh giữa việc sử dụng linear-frequency spectrograms và mel-scale spectrograms làm đầu vào của WaveNet, và mel spectrograms đã cho hiệu suất tốt hơn với sự biểu diễn nhỏ gọn hơn mà không làm mất chất lượng âm thanh.

Nhìn chung, Tacotron 2 đại diện cho một bước tiến đáng kể trong công nghệ TTS. Bằng cách vượt qua những hạn chế của các kỹ thuật trước đó và kết hợp sức mạnh của mô hình sequence-to-sequence và vocoder WaveNet, Tacotron 2 đã thành công trong việc tổng hợp giọng nói tự nhiên từ văn bản. Khi nghiên cứu hướng tiếp tục trong lĩnh vực này, chúng ta có thể mong đợi sự cải thiện và tiến bộ hơn trong các hệ thống TTS, làm cho giọng nói tổng hợp trở nên khó phân biệt hơn so với giọng nói của con người.

1. MỤC TIÊU ĐỒ ÁN

Bài toán tổng hợp tiếng nói (Speech Synthesis) là bài toán giải quyết việc chuyển đổi văn bản thành tiếng nói. Đây là bài toán có nhiều ứng dụng trong thực tế. Mô hình tổng hợp tiếng nói có thể được tích hợp trong các ứng dụng, trang web đọc báo, đọc sách,…

Trong báo cáo này, tôi trình bày về việc giải quyết bài toán chuyển đổi văn bản tiếng Anh thành tiếng nói bằng phương pháp sử dụng mô hình Tacotron 2.

Bài toán chuyển đổi văn bản tiếng Anh thành tiếng nói:

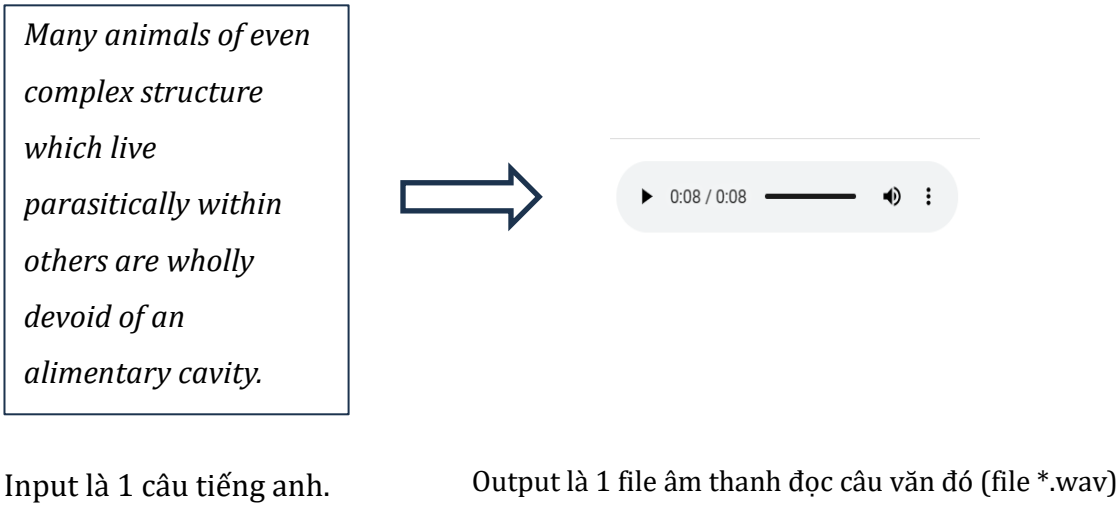

Hình 1. Mô tả bài toán

2. CÁC NGHIÊN CỨU LIÊN QUAN

Các nghiên cứu về tổng hợp tiếng nói đã có từ rất lâu đời, bắt đầu từ những năm 1950. Trong những năm đầu, các hệ thống tổng hợp tiếng nói chủ yếu sử dụng các kỹ thuật kỹ thuật số để tạo ra tiếng nói. Các kỹ thuật này bao gồm:

- Tổng hợp dựa trên mô hình nguồn âm (source-filter model): mô hình này mô tả tiếng nói là sự kết hợp của một nguồn âm (thường là giọng nói của con người) và một bộ lọc (thường là bộ lọc hình sin).

- Tổng hợp dựa trên việc ghép nối các đơn vị âm (concatenation model): mô hình này tạo ra tiếng nói bằng cách ghép nối các đơn vị âm (phoneme) đã được ghi lại trước đó.

Các hệ thống tổng hợp tiếng nói sử dụng các kỹ thuật này có chất lượng không cao, giọng nói tạo ra thường không tự nhiên và khó nghe.

Trong những năm gần đây, các nghiên cứu về tổng hợp tiếng nói đã đạt được những tiến bộ đáng kể nhờ sự phát triển của trí tuệ nhân tạo, đặc biệt là học sâu. Các mô hình học sâu có thể học được các mối quan hệ phức tạp giữa văn bản và tiếng nói, từ đó tạo ra tiếng nói tự nhiên và chân thực hơn.

Một trong những mô hình học sâu được sử dụng phổ biến trong tổng hợp tiếng nói là mô hình Tacotron 2. Mô hình này được phát triển bởi Google AI vào năm 2017. Tacotron 2 sử dụng kiến trúc encoder-decoder với một mạng neural network (NN) để chuyển đổi văn bản thành một chuỗi các thông số âm học (acoustic parameters). Một mạng NN khác sẽ sử dụng các thông số âm học này để tạo ra tiếng nói.

Mô hình Tacotron 2 đã đạt được những thành tựu đáng kể trong việc cải thiện chất lượng tổng hợp tiếng nói. Giọng nói tạo ra bởi Tacotron 2 có độ tự nhiên cao, không khác biệt nhiều so với giọng nói của con người.

Ngoài mô hình Tacotron 2, các nghiên cứu về tổng hợp tiếng nói còn phát triển một số mô hình khác, bao gồm:

- Mô hình WaveNet được phát triển bởi Google AI vào năm 2016. WaveNet sử dụng kiến trúc mạng neural network tái tạo (generative neural network) để tạo ra tiếng nói trực tiếp từ văn bản.
- Mô hình DeepVoice 3 được phát triển bởi Baidu vào năm 2018. DeepVoice 3 sử dụng kiến trúc mạng neural network tích chập (convolutional neural network) để tạo ra tiếng nói.

Các mô hình tổng hợp tiếng nói dựa trên học sâu đã mở ra những khả năng mới cho lĩnh vực này. Các hệ thống tổng hợp tiếng nói sử dụng các mô hình này có thể tạo ra tiếng nói tự nhiên và chân thực hơn, từ đó có thể được ứng dụng trong nhiều lĩnh vực khác nhau, bao gồm:

- Trợ lý ảo: các hệ thống trợ lý ảo như Siri, Alexa, Google Assistant thường sử dụng tổng hợp tiếng nói để tạo ra giọng nói của người dùng.
- Giáo dục: tổng hợp tiếng nói có thể được sử dụng để tạo ra các bài giảng hoặc các nội dung học tập khác.
- Giải trí: tổng hợp tiếng nói có thể được sử dụng để tạo ra các nhân vật ảo, các bản nhạc, hoặc các tác phẩm nghệ thuật khác.

Với sự phát triển không ngừng của trí tuệ nhân tạo, các nghiên cứu về tổng hợp tiếng nói sẽ tiếp tục được cải tiến, giúp tạo ra các hệ thống tổng hợp tiếng nói có chất lượng ngày càng cao.

3. MÔ HÌNH TACOTRON 2

3.1. Kiến trúc chung của mô hình

Mô hình Tacotron 2 gồm 2 phần:

+ Phần 1. Spectrogram Prediction Network: chuyển đổi Input Text thành Mel – Spectrogram.

+ Phần 2. Vocoder: chuyển đổi Mel-Spectrogram thành Waveform (tức là file audio *.wav)

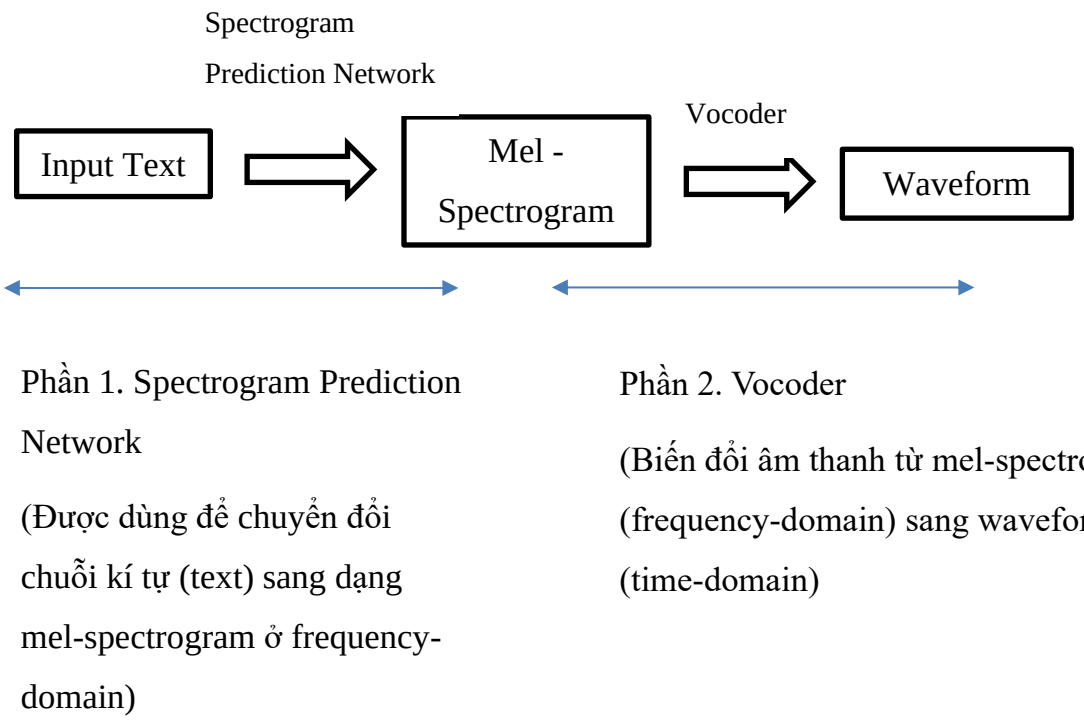

Hình 2. Kiến trúc chung của mô hình Tacotron 2

3.2. Phần 1. Spectrogram Prediction Network

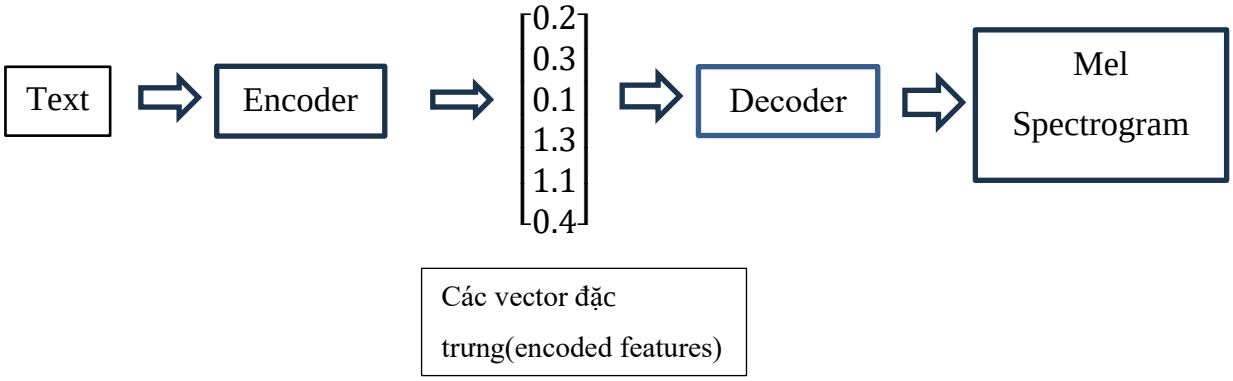

Hình 3. Kiến trúc mô hình Spectrogram Prediction Network

3.2.1. Quá trình Encoder

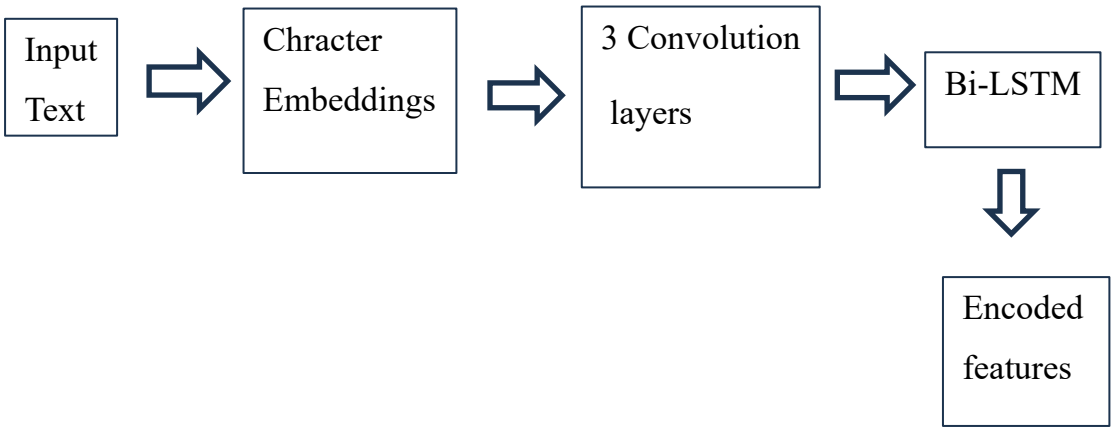

Hình 4. Mô hình Encoder

Các ký tự Input được biểu diễn thành các vector embedding 512 chiều. Các vector này được đưa qua một ngăn xếp 3 lớp convolution, mỗi lớp chứa 512 filter kích thước 5 x 1, nghĩa là mỗi filter trải rộng trên 5 ký tự, theo sau đó là batch normalization và hàm kích hoạt ReLU. Batch normalization giúp điều chỉnh phân phối của dữ liệu đầu vào ở mỗi lớp, nhằm mục đích tăng tốc độ huấn luyện và cải thiện khả năng hội tụ của mạng nơ-ron, đồng thời Giảm độ nhạy cảm đối với việc khởi tạo trọng số và lựa chọn tốc độ học. Hàm kích hoạt ReLU

(Rectified Linear Unit activation) là hàm kích hoạt phi tuyến tính được sử dụng rộng rãi trong các mạng nơ-ron. ReLU cho phép mô hình học các mối quan hệ phức tạp hơn trong dữ liệu bằng cách loại bỏ các giá trị âm và giữ lại các giá trị dương. Các lớp convolutional mô hình hóa ngữ cảnh “long-term” (ví dụ, term N-grams) trong chuỗi ký tự đầu vào. Nghĩa là bằng cách trượt filter trên dữ liệu đầu vào, mô hình giúp phát hiện ra mối quan hệ giữa các ký tự không chỉ ở vị trí liền kề mà còn ở khoảng cách xa hơn (do sự chồng lấp của các filter khi trượt), điều này giúp mô hình hiểu rõ hơn về ngữ cảnh của văn bản và có thể tạo ra giọng nói tự nhiên hơn. Output của lớp convolution cuối cùng được đi qua một lớp single bi-directional LSTM chứa 512 unit (nghĩa là mỗi direction chứa 256 unit) để tạo ra các vector đặc trưng của chuỗi ký tự đầu vào. Các vector đặc trưng này sau đó sẽ được chuyển tới quá trình decoder, sẽ được trình bày trong phần 3.2.2. Quá trình Decoder ở bên dưới.

3.2.2. Quá trình Decoder

Các vector đặc trưng có được sau quá trình encoder sẽ được tổng hợp bởi 1 mạng attention để tạo ra 1 vector ngữ cảnh có chiều dài cố định cho mỗi bước output của decoder. Mô hình sử dụng một loại attention đặc biệt gọi là "location-sensitive attention". Loại attention này mở rộng cơ chế attention cơ bản bằng cách sử dụng các trọng số attention tích lũy từ các bước thời gian trước đó của decoder như một đặc trưng bổ sung. Điều này giúp model chú ý đến những phần quan trọng của chuỗi đầu vào và tránh lặp lại hoặc bỏ sót thông tin. Các xác suất attention được tính toán sau khi chuyển đổi các input và các đặc trưng location tới không gian vector ẩn 128 chiều. Các đặc trưng location được tính toán bằng cách sử dụng 32 filter convolution 1-D, mỗi filter có chiều dài 31.

Decoder của mô hình này là 1 mạng autoregressive recurrent neural network. Decoder nhận đầu vào là chuỗi ký tự đã được mã hóa (encoded input sequence) từ encoder. Sau đó xử lý chuỗi ký tự đã được mã hóa theo từng frame. Ở mỗi frame, decoder sử dụng cả đầu vào hiện tại và đầu ra của chính nó từ các frame trước đó để dự đoán khung phổ mel-spectrogram tiếp theo. Quá trình này lặp lại cho đến khi toàn bộ phổ mel-spectrogram được dự đoán.

Các thành phần của Decoder:

1. Mạng tiền xử lý (pre-net):

- Dự đoán từ bước thời gian trước được đưa qua một mạng nhỏ gồm 2 lớp kết nối đầy đủ, mỗi lớp có 256 đơn vị ẩn ReLU.

- Mạng này hoạt động như một nút thắt thông tin, giúp loại bỏ nhiễu và tập trung vào thông tin quan trọng cho việc học cơ chế chú ý (attention).

2. Mạng nhớ dài hạn LSTM:

- Đầu ra của mạng tiền xử lý được kết hợp với vector ngữ cảnh attention.

- Tổng hợp này được đưa qua 2 lớp LSTM một chiều, mỗi lớp có 1024 đơn vị.

- LSTM giúp nắm bắt các mối quan hệ xa trong chuỗi dữ liệu và tạo ra biểu diễn ngữ nghĩa phong phú hơn.

3. Dự đoán khung phổ mel-spectrogram:

- Đầu ra của LSTM và vector ngữ cảnh attention được kết hợp và biến đổi tuyến tính để dự đoán khung phổ mel tiếp theo.

4. Mạng xử lý hậu kỳ (post-net):

- Phổ mel được dự đoán được đưa qua mạng gồm 5 lớp tích chập, mỗi lớp có 512 bộ lọc kích thước 5x1 với chuẩn hóa theo nhóm (batch normalization).

- Mạng này dự đoán một phần dư (residual) để bổ sung vào dự đoán ban đầu, giúp cải thiện chất lượng tổng thể của phổ mel.

Hàm mất mát (loss function) được sử dụng trong quá trình huấn luyện là Mean Squared Error (MSE). MSE được tính toán cả trước và sau khi phổ mel đi qua post-net. Điều này giúp đảm bảo rằng cả decoder và post-net đều được tối ưu hóa để giảm thiểu sai số tổng thể. Các giá trị MSE trước và sau post-net được cộng lại với nhau để tạo thành một hàm mất mát duy nhất. Việc sử dụng hàm mất mát MSE tổng hợp này giúp thúc đẩy quá trình hội tụ (convergence) của quá trình huấn luyện, nghĩa là giúp model học nhanh hơn và đạt được kết quả tốt hơn.

Model dự đoán thời điểm kết thúc quá trình tổng hợp giọng nói bằng cách kết hợp đầu ra của lớp LSTM và vector ngữ cảnh attention. Kết quả được chiếu xuống một giá trị vô hướng và được đưa qua hàm kích hoạt sigmoid để tạo ra một xác suất nằm trong khoảng từ 0 đến 1. Xác suất này được gọi là "dự đoán stop token". Trong quá trình suy luận, nếu xác suất này vượt quá ngưỡng 0.5, quá trình tổng hợp sẽ kết thúc.

Lợi ích của cách tiếp cận này là giúp model tự động điều chỉnh độ dài của giọng nói được tổng hợp dựa trên nội dung của văn bản đầu vào, giúp tạo ra các giọng nói tự nhiên hơn và hiệu quả hơn.

Các kỹ thuật như dropout và zoneout được sử dụng để ngăn chặn hiện tượng overfitting và cải thiện khả năng tổng quát hóa của model. Dropout với xác suất 0.5 cũng được áp dụng trong quá trình suy luận, nhưng chỉ cho các lớp trong pre-net của decoder để tạo ra sự đa dạng trong các giọng nói được tổng hợp.

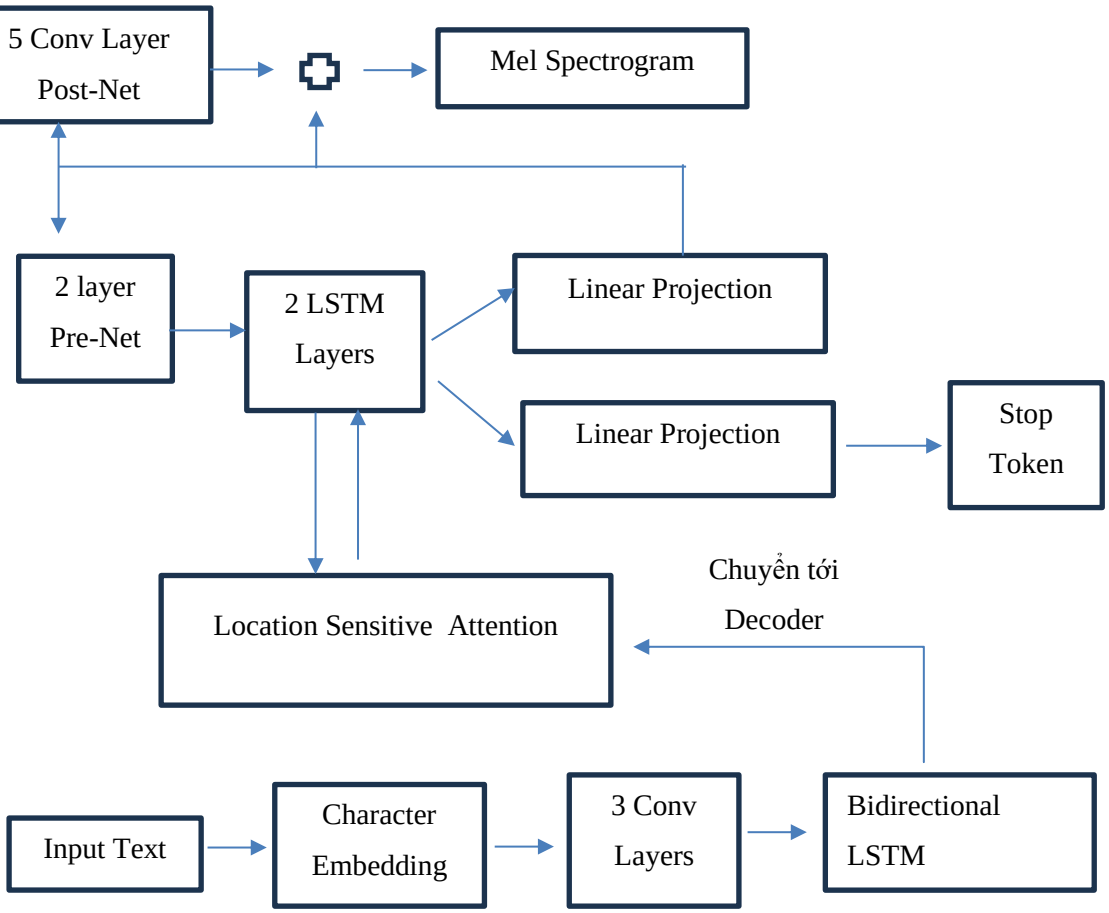

Hình 5. Mô hình Spectrogram Prediction Network chi tiết

3.3. Phần 2. Vocoder

Được dùng để biến đổi dữ liệu từ định dạng Mel-spectrogram sang waveform (miền thời gian) mà con người có thể nghe được

Hình 6. Vocoder

Vocoder:

- Mô hình WaveNet:

WaveNet là một mô hình mạng lưới thần kinh sâu được tạo ra để tạo ra sóng âm thô. Mô hình này dựa trên kiến trúc PixelCNN và có những đặc điểm chính sau:

Phân tách tín hiệu theo từng mẫu: WaveNet dự đoán từng mẫu âm thanh (x_t) dựa trên tất cả các mẫu trước đó ($x_1, \ldots, x_{t-1}$), cho phép mô hình nắm bắt mối quan hệ phụ thuộc theo thời gian phức tạp của âm thanh.

Sử dụng các dilated causal convolution: Điều này giúp WaveNet có trường tiếp nhận lớn (receptive field) mà không cần nhiều lớp, cho phép mô hình xử lý những phụ thuộc theo thời gian xa nhau của âm thanh. Trường tiếp nhận càng lớn, mô hình càng có thể nắm bắt được nhiều thông tin từ quá khứ để dự đoán mẫu âm thanh tiếp theo một cách chính xác hơn.

Phân bố softmax cho từng mẫu: Thay vì mô hình hóa trực tiếp các giá trị âm thanh liên tục, WaveNet phân tách tín hiệu thành 256 cấp độ phân biệt và gán một phân bố softmax cho mỗi cấp độ. Điều này cho phép mô hình dự đoán xác suất xuất hiện của mỗi cấp độ cho mẫu âm thanh tiếp theo, do đó linh hoạt hơn so với các phương pháp mô hình hóa phân bố liên tục.

Các đơn vị kích hoạt có cổng (gated activation units): WaveNet sử dụng các đơn vị kích hoạt này để điều chỉnh thông tin được truyền qua mạng. Bằng cách kết hợp hàm tanh và

hàm sigmoid, mô hình có thể học cách chọn lọc thông tin quan trọng cho việc dự đoán mẫu âm thanh tiếp theo.

Kết nối dư và kết nối bỏ qua (residual and skip connections): Những kết nối này giúp truyền tín hiệu trực tiếp từ các lớp trước ra các lớp sau, cải thiện luồng thông tin trong mạng và tránh vấn đề biến mất gradien (gradient vanishing) thường gặp trong các mạng sâu.

Nhờ những đặc điểm này, WaveNet có thể tạo ra sóng âm thô với độ trung thực cao, được đánh giá là hay hơn đáng kể so với các hệ thống tổng hợp giọng nói truyền thống. Mô hình này có thể áp dụng cho nhiều ứng dụng khác nhau như tổng hợp giọng nói, tạo nhạc, cải thiện chất lượng giọng nói, chuyển giọng nói, tách nguồn âm thanh…

- Mô hình WaveGlow:

Mô hình WaveGlow là một mô hình dựa trên luồng (flow-based) được thiết kế để tạo ra giọng nói chất lượng cao từ mel-spectrogram. Mô hình này kết hợp các ý tưởng từ hai mô hình: Glow và WaveNet.

Mô hình WaveGlow có thể được xem như một mạng neural tích chập mà các tầng được thiết kế theo cấu trúc đặc biệt để ánh xạ từ mel-spectrogram sang dữ liệu âm thanh thô. Mô hình này không yêu cầu lan truyền tự động (auto-regressive), nghĩa là nó không phụ thuộc vào các mẫu âm thanh trước đó để tạo ra các mẫu âm thanh tiếp theo.

Quá trình huấn luyện mô hình WaveGlow được thực hiện chỉ thông qua việc tối đa hóa hàm mất mát hợp lý (likelihood loss) dựa trên dữ liệu huấn luyện. Điều này giúp quá trình huấn luyện đơn giản và ổn định.

Giải thuật của WaveGlow cho phép tạo ra âm thanh chất lượng cao với tốc độ nhanh hơn 500kHz trên một GPU NVIDIA V100. So sánh các điểm số ý kiến trung bình (Mean Opinion Scores) cho thấy mô hình này cung cấp chất lượng âm thanh tương đương với các mô hình WaveNet chất lượng cao nhất hiện có.

Mô hình WaveGlow có thể giúp giảm độ phức tạp trong việc huấn luyện và triển khai công nghệ tổng hợp giọng nói chất lượng cao.

4. BỘ DỮ LIỆU SỬ DỤNG

Sử dụng bộ dữ liệu LJ Speech gồm 13100 cặp audio-phụ đề tiếng Anh.

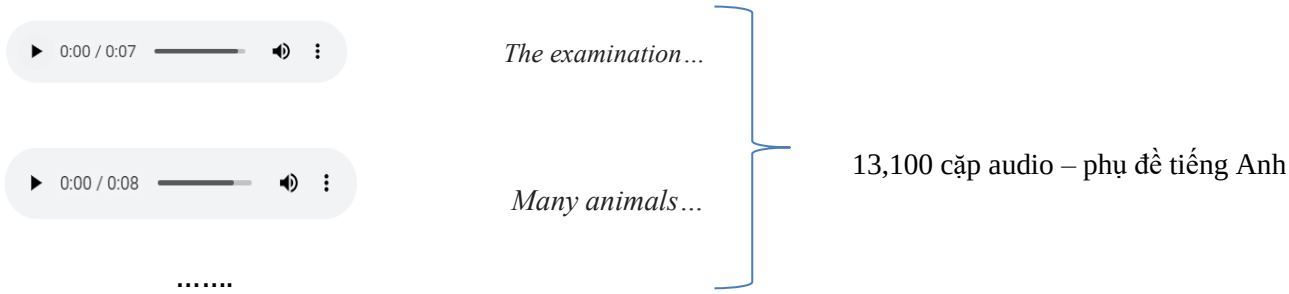

Hình 7. Dữ liệu sử dụng

- Lấy 12000 cặp audio – phụ đề làm tập train
- Lấy 1000 cặp audio – phụ đề làm tập validation
- Lấy 50 câu phụ đề làm tập test

Tạo các file train.txt và val.txt để thuận tiện cho việc huấn luyện mô hình

File *train.txt* chứa đường dẫn tới mỗi file audio trong tập train và phụ đề tương ứng của chúng.

File *val.txt* chứa đường dẫn tới mỗi file audio trong tập val và phụ đề tương ứng của chúng.

```
Path/to/LJ0500234.wav|It has used...
Path/to/LJ019-0373.wav|to avail himself...
Path/to/LJ050-0207.wav|Although Chief...
.........
```

train.txt

```
Path/to/LJ022-0023.wav|The overwhelming...
Path/to/LJ043-0030.wav|If somebody did that...
Path/to/LJ005-0201.wav|as is shown by...
.........
```

val.txt

Hình 8. Dữ liệu huấn luyện

5. HUẤN LUYỆN MÔ HÌNH

Phần 1. Huấn luyện mô hình Spectrogram Prediction Network – Mô hình chuyển đổi text thành spectrogram

Trong quá trình huấn luyện, các file audio trong tập train được chuyển thành các true spectrogram. Các câu phụ đề được chuyển thành các predicted spectrogram với các tham số khởi tạo ngẫu nhiên của mô hình Spectrogram Predict Network. Tham số mô hình spectrogram predict network được cập nhật bằng hàm loss Mean Squared Error

MSELoss(true_spectrogram, predicted_spectrogram)

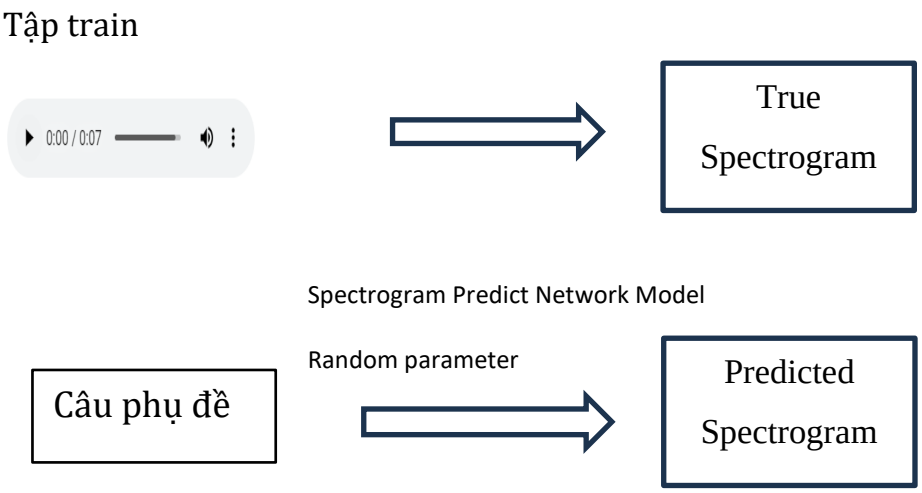

Hình 9. Huấn luyện mô hình Spectrogram Predict Network

Phần 2. Huấn luyện mô hình Vocoder – Chuyển đổi Mel Spectrogram thành audio:

Sử dụng mô hình WaveGlow đã được huấn luyện sẵn của NVIDIA.

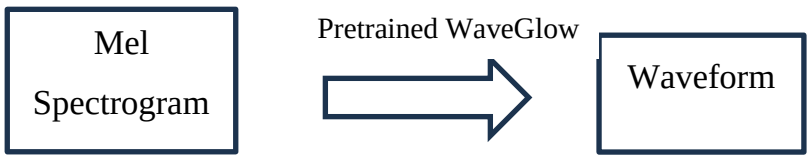

Hình 10. WaveGlow

6. PHƯƠNG PHÁP ĐÁNH GIÁ KẾT QUẢ

- Sử dụng độ đo mean opinion scores (MOS). MOS là một hệ thống tính điểm chủ quan cho phép người đánh giá đánh giá chất lượng cảm nhận của giọng nói tổng hợp theo thang điểm từ 1 đến 5. Những điểm số này thường được thu thập thông qua các bài kiểm tra nghe, trong đó người tham gia là con người lắng nghe và đánh giá các mẫu giọng nói tổng hợp.

7. THỬ NGHIỆM VỚI BỘ DỮ LIỆU LJ SPEECH

- Huấn luyện phần Spectrogram Prediction Network của mô hình Tacotron 2: Huấn luyện bằng GPU T4 x2 của Kaggle với 100 epoch trong 13.5 tiếng

- Huấn luyện phần Voocoder: Sử dụng mô hình WaveGlow của NVIDIA đã được huấn luyện sẵn.

The examination and testimony of the experts enabled the Commission to conclude that five shots may have been fired.

Model Spectrogram +
Model Pretrained

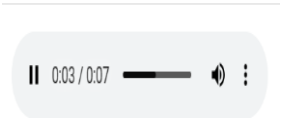

8. TÓM TẮT KẾT QUẢ ĐẠT ĐƯỢC

Thử nghiệm trên một tập test gồm 50 câu tiếng anh (lấy từ bộ LJSpeech):

- Sử dụng phương pháp đánh giá mean opinion scores (MOS) với 1 người đánh giá: Chấm điểm mỗi câu trên thang điểm 5 dựa trên độ chính xác và mức độ tự nhiên của giọng nói. Kết quả đánh giá trung bình đạt: 4.5

Bảng kết quả đánh giá trên tập test:

STT	Câu trong tập test	Điểm của tiếng nói được tạo ra bởi mô hình.
1	Printing, in the only sense with which we are at present concerned, differs from most if not from all the arts and crafts represented in the Exhibition	4.7
2	For although the Chinese took impressions from wood blocks engraved in relief for centuries before the woodcutters of the Netherlands, by a similar process	4
3	Now, as all books not primarily intended as picture-books consist principally of types composed to form letterpress,	4.9
4	The earliest book printed with movable type, the aforesaid Gutenberg Bible, is printed in letters which are an exact imitation	4.2
5	of the more formal ecclesiastical writing which obtained at that time; this has since been called "missal type,"	4.6
6	But the first Bible actually dated (which also was printed at Maintz by Peter Schoeffer in the year 1462)	4
7	On the whole the type of this book may be considered the ne-plus-ultra of Gothic type,	4.1
8	In 1465 Sweynheim and Pannartz began printing in the monastery of Subiaco near Rome,	5.1
9	After his death in the "fourteen eighties," or at least by 1490, printing in Venice had declined very much;	4.5

10	they must be considered to have ended the age of fine printing in Italy.	4.6
11	Jenson, however, had many contemporaries who used beautiful type,	4.7
12	some of which -- as, e.g., that of Jacobus Rubeus or Jacques le Rouge -- is scarcely distinguishable from his.	4
13	It was these great Venetian printers, together with their brethren of Rome, Milan,	4.4
14	Parma, and one or two other cities, who produced the splendid editions of the Classics, which are one of the great glories of the printer's art.	4.6
15	the greater part of these Italian printers, it should be mentioned, were Germans or Frenchmen, working under the influence of Italian opinion and aims.	4.3
16	It must be understood that through the whole of the fifteenth and the first quarter of the sixteenth centuries	4.8
17	Even in Italy most of the theological and law books were printed in Gothic letter	4.2
18	which was generally more formally Gothic than the printing of the German workmen	4.7
19	This was notably the case with the early works printed at Ulm, and in a somewhat lesser degree at Augsburg.	4.5
20	In fact Gunther Zeiner's first type (afterwards used by Schussler) is remarkably like the type of the before-mentioned Subiaco books.	4.2

21	In the Low Countries and Cologne, which were very fertile of printed books, Gothic was the favorite.	4.3
22	The characteristic Dutch type, as represented by the excellent printer Gerard Leew, is very pronounced and uncompromising Gothic.	4.9
23	In England about this time, an attempt was made (notably by Caslon, who started business in London as a type-founder in 1720)	4.7
24	The seventeenth century founts were bad rather negatively than positively.	5.1
25	But for the beauty of the earlier work they might have seemed tolerable.	5.1
26	The Chiswick press in 1844 revived Caslon's founts, printing for Messrs. Longman the Diary of Lady Willoughby.	4.7
27	This experiment was so far successful that about 1850 Messrs. Miller and Richard of Edinburgh	5
28	It is discouraging to note that the improvement of the last fifty years is almost wholly confined to Great Britain.	4.4
29	In the old print each figure has its definite individuality, and one cannot be mistaken for the other	3.9
30	till, 1808, the lowest point was touched of 197 debtors and 182 felons, or 379 in all.	5.1
31	300 debtors and 900 criminals in Newgate, or twelve hundred prisoners in all.	4.9

32	Trustworthy evidence is forthcoming to the effect that these high figures were constantly maintained for many months at a time.	4.8
33	The middle yard was at first given up to the least heinous offenders. After 1812 it changed functions with the chapel yard.	5.1
34	It was fifty feet by twenty-five, and had five wards each thirty-eight by fifteen. At one end of the yard was an arcade	4.5
35	The master felons' side consisted of a yard the same size as the preceding, appropriated nominally to the most decent and better-behaved prisoners	4.4
36	The state side was the part stolen from the female felons' side.	4.4
37	Beyond the press yard were three stories, condemned cells, fifteen in all, with vaulted ceilings nine feet high to the crown of the arch.	4.1
38	Security was provided for in these condemned cells by lining the substantial stone walls with planks studded with broad-headed nails;	4.9
39	These surely, I thought," says Mr. Neild, "were bad enough! But it was not so. End quote.	4.6
40	Neild gives a list of the various items charged upon a debt of £10, which included instructions to sue,	5

41	The foregoing rentals and payments for privileges, together with fees exacted on commitment and discharge, went to the marshal or keeper of the prison,	4.1
42	Dissolute habits prevailed on all sides; drunkenness was universal, gambling perpetual.	4.6
43	How to make most profit out of the wretched denizens of the jail was the marshal's only care. He got a rent for the coffee-house and the bake-house;	4.2
44	A committee of the House of Commons investigated the charges against Bambridge, who was proved to have connived at the escape of some debtors,	4.2
45	In consequence of these disclosures, both Bambridge and Huggin, his predecessor in the office, were committed to Newgate,	3.9
46	The same evils of overcrowding, uncleanliness, want of medical attendance,	4.3
47	There was no distinct place for the female debtors, who lived in the same galleries as the men.	5
48	The prison was a nest of abuses, like its neighbor the King's Bench	3.9
49	Drunkenness was not common, chiefly because liquor was not to be had freely, although the tapster paid a rent of two guineas a week for permission to sell it.	4.2
50	The compters of Ludgate, Giltspur Street, and the Borough were discontinued as debtors' prisons (as was Newgate also)	3.9

9. CÁC ĐIỂM HẠN CHẾ VÀ CÁC ĐIỂM CẦN CẢI TIẾN

- Mô hình được huấn luyện trên 1 bộ dữ liệu có kích thước lớn, đòi hỏi GPU với thời gian huấn luyện dài.

- Trong đồ án này, phương pháp đánh giá mean opinion scores (MOS), được đánh giá bằng một người nên có thể thiếu tính khách quan. Người đánh giá là người Việt nên khi đánh giá mức độ tự nhiên của giọng nói tiếng Anh, có thể đưa ra những đánh giá thiếu chính xác.

TÀI LIỆU THAM KHẢO

Shen, J. *et al.* (2018) *Natural TTS synthesis by conditioning WaveNet on Mel Spectrogram predictions*, *arXiv.org*. Available at: https://arxiv.org/abs/1712.05884

Prenger, R., Valle, R. and Catanzaro, B. (2018) *Waveglow: A flow-based generative network for speech synthesis*, *arXiv.org*. Available at: https://arxiv.org/abs/1811.00002

Oord, A. van den *et al.* (2016) *WaveNet: A generative model for raw audio*, *arXiv.org*. Available at: https://arxiv.org/abs/1609.03499