BÁO CÁO ĐỒ ÁN

MÔN: CÁC KỸ THUẬT HỌC SÂU VÀ ỨNG DỤNG – CS431.N21

ĐỀ TÀI:

Phát Sinh Câu Mô Tả Ảnh Sử Dụng Mô Hình Transformer

(Image Captioning Using Transformer)

Sinh viên thực hiện: Nguyễn Tam Điệp

MSSV: 19521360

Giảng viên hướng dẫn: Nguyễn Vinh Tiệp

TP.HCM, tháng 6, năm 2023

Mục lục

1. Bài toán Image Captioning 2

2. Kiến trúc encoder-decoder 2

3. Encoder sử dụng Vision Transformer (ViT) 3

4. Decoder sử dụng GPT2 8

5. Phương pháp đánh giá 9

6. Thử nghiệm 10

Tài liệu tham khảo 18

1. Bài toán Image Captioning

Phát sinh câu mô tả ảnh (Image Captioning) là quá trình tạo ra câu mô tả dưới dạng văn bản của một tấm ảnh. Đây là một bài toán kết hợp của hai lĩnh vực thị giác máy tính và xử lý văn bản. Trong đó, quá trình đầu tiên cần phải thực hiện là hiểu ảnh và biểu diễn bằng một vector biểu diễn. Sau đó là quá trình phát sinh ra câu mô tả từ vector biểu diễn ở bước trước đó.

Input:

Output:

a soccer player kicking a soccer ball

2. Kiến trúc encoder-decoder

Mô hình Vision Encoder Decoder có thể được sử dụng để tạo một mô hình image-text bằng cách sử dụng một mô hình pre-trained Transformer-based vision (ví dụ ViT, BeiT, DeiT, Swin) làm encoder và sử dụng một mô hình pre-trained language (ví dụ GPT2, BERT) làm decoder.

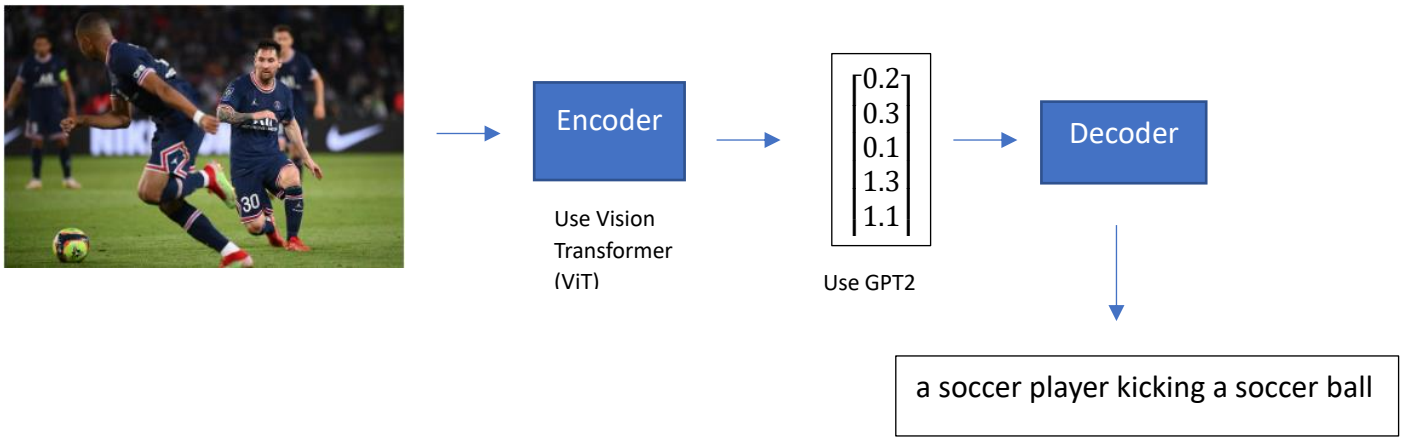

3. Encoder sử dụng Vision Transformer (ViT)

Sử dụng mô hình ViT như một image encoder

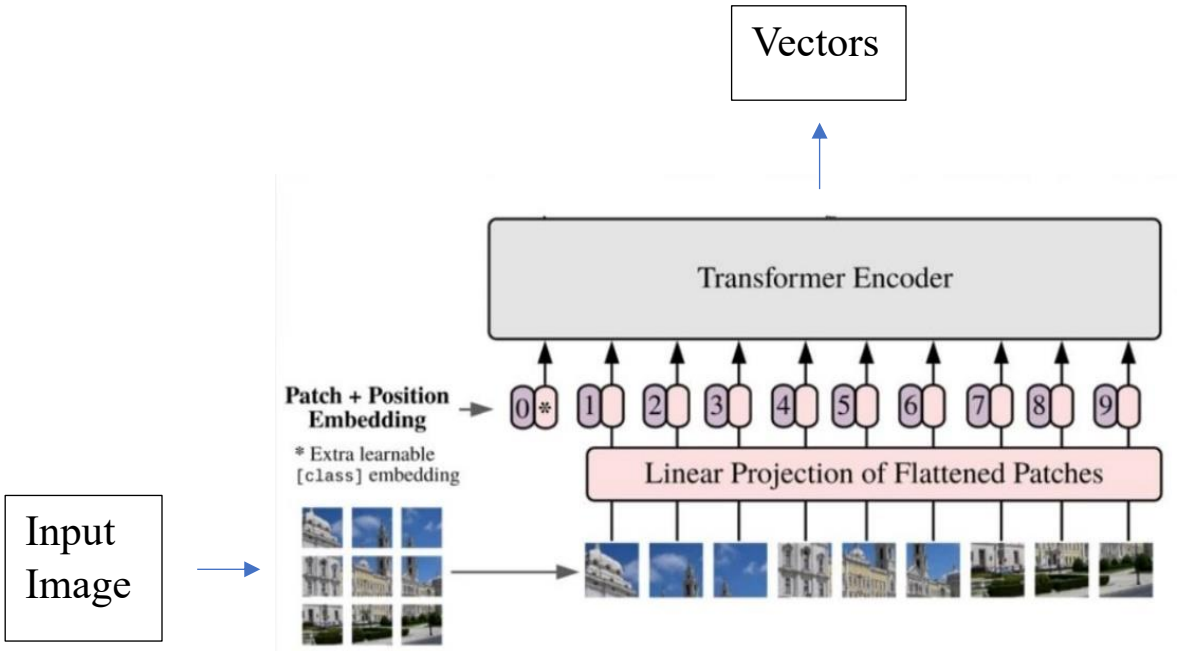

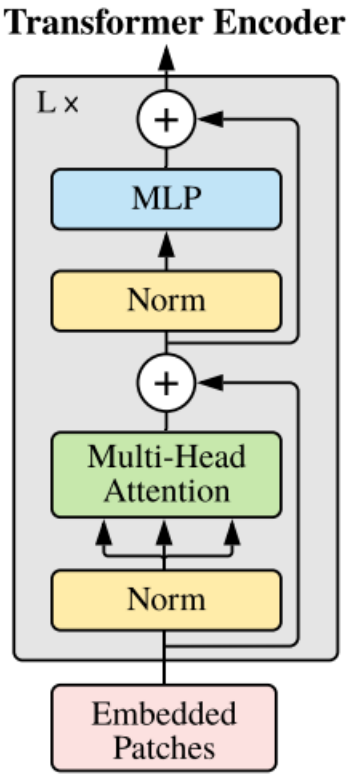

Ảnh đầu vào sẽ được cắt thành nhiều miếng ảnh nhỏ hình vuông. Tương tự như tron các mô hình xử lý ngôn ngữ tự nhiên, khi mà một câu được chia nhỏ thành nhiều đơn vị từ . Ở đây, các miếng ảnh hình vuông cũng đóng vai trò như các đơn vị từ.

Các miếng ảnh hình vuông này sẽ được chuyển đổi thành các vector, sau đó kết hợp với các vector thể hiện vị trí thứ tự của các bức ảnh – Position Embedding. Word embeddings phần nào cho giúp ta biểu diễn ngữ nghĩa của một từ, tuy nhiên cùng một từ ở vị trí khác nhau của câu lại mang ý nghĩa khác nhau. Đó là lý do Transformers có thêm một phần Positional Encoding để inject thêm thông tin về vị trí của một từ.

$$PE_{(pos,2i)} = \sin\left(pos/10000^{2i/d_{\text{model}}}\right)$$
$$PE_{(pos,2i+1)} = \cos\left(pos/10000^{2i/d_{\text{model}}}\right)$$

Trong đó pos là vị trí của từ trong câu, PE là giá trị phần tử thứ i trong embeddings có độ dài d_{model}. Sau đó ta cộng PE vector và Embedding vector:

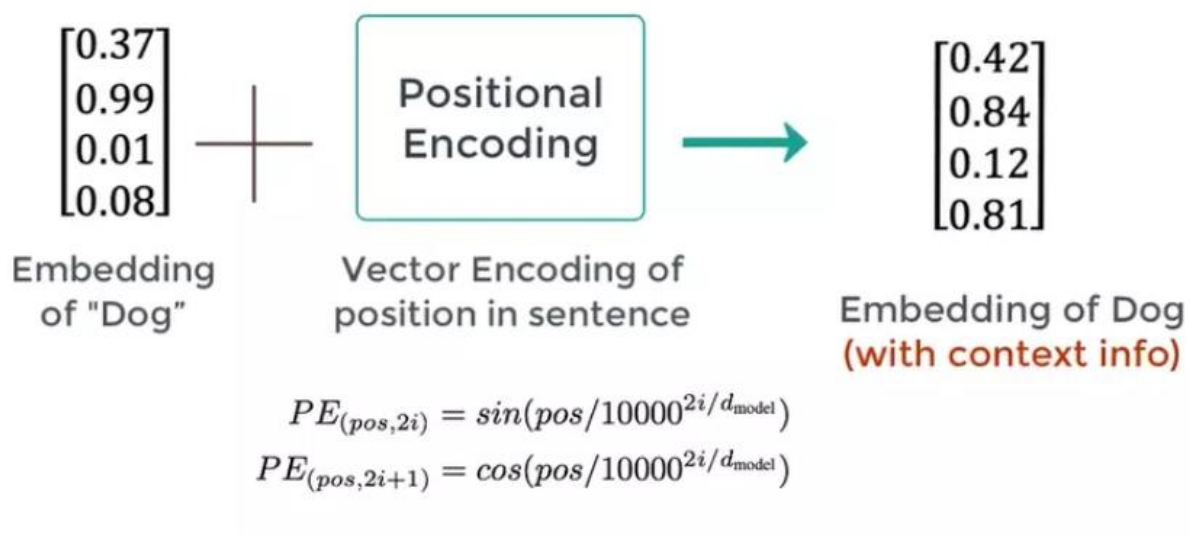

Sau đó các vector này đi qua mô hình transformer.

Self-Attention là cơ chế giúp Transformers "hiểu" được sự liên quan giữa các từ trong một câu. Ví dụ như từ "kicked" trong câu "I kicked the ball" (tôi đã đá quả bóng) liên quan như thế nào đến các từ khác? Rõ ràng nó liên quan mật thiết đến từ "I" (chủ ngữ), "kicked" là chính nó lên sẽ luôn "liên quan mạnh" và "ball" (vị ngữ). Ngoài ra từ "the" là giới từ nên sự liên kết với từ "kicked" gần như không có.

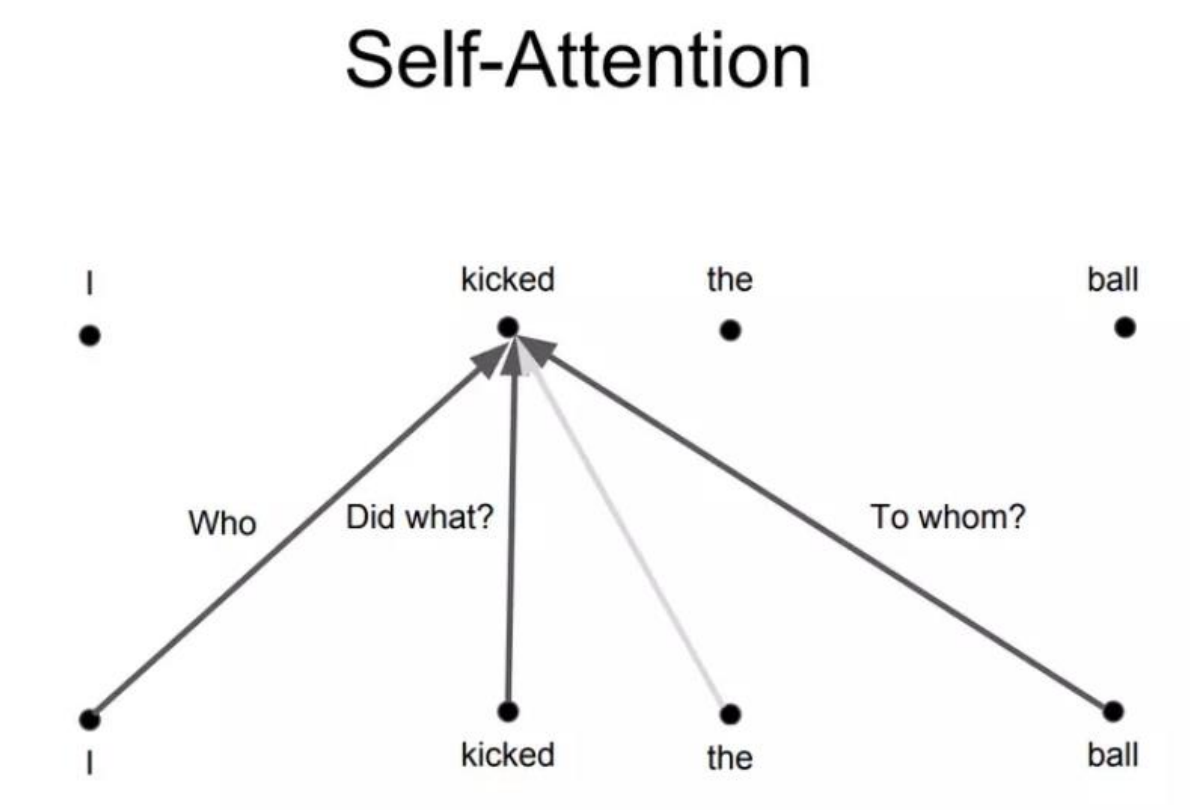

Quay trở lại với kiến trúc Transformer Encoder ở trên, có thể thấy đầu vào của các module Multi-head Attention (bản chất là Self-Attention) có 3 mũi tên, đó chính là 3 vectors Querys (Q), Keys (K) và Values (V). Từ 3 vectors này, ta sẽ tính vector attention Z cho một từ theo công thức sau:

$$Z = \text{softmax}\left(\frac{Q \cdot K^T}{\sqrt{Dimension\ of\ vector\ Q, K \text{ or } V}}\right) \cdot V$$

Công thức này khá đơn giản, nó được thực hiện như sau. Đầu tiên, để có được 3 vectors Q, K, V, input embeddings được nhân với 3 ma trận trọng số tương ứng (được tune trong quá trình huấn luyện) WQ, WK, WV.

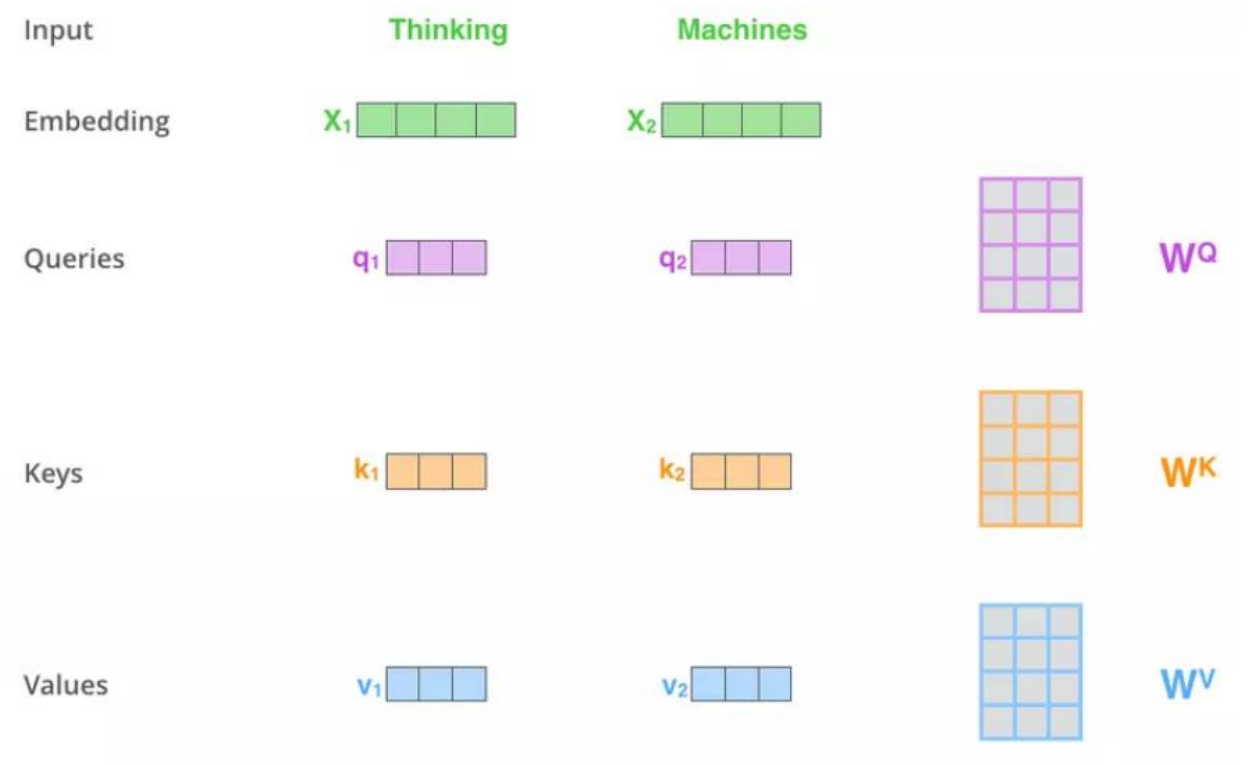

Lúc này, vector K đóng vai trò như một khóa đại diện cho từ, và Q sẽ truy vấn đến các vector K của các từ trong câu bằng cách nhân chập với những vector này. Mục đích của phép nhân chập để tính toán độ liên quan giữa các từ với nhau. Theo đó, 2 từ liên quan đến nhau sẽ có "Score" lớn và ngược lại.

Bước thứ 2 là bước "Scale", đơn giản chỉ là chia "Score" cho căn bậc hai của số chiều của Q/K/V (trong hình chia 8 vì Q/K/V là 64-D vectors). Việc này giúp cho giá trị "Score" không phụ thuộc vào độ dài của vector Q/K/V

Bước thứ 3 là softmax các kết quả vừa rồi để đạt được một phân bố xác suất trên các từ.

Bước thứ 4 ta nhân phân bố xác suất đó với vector V để loại bỏ những từ không cần thiết (xác suất nhỏ) và giữ lại những từ quan trọng (xác suất lớn).

Ở bước cuối cùng, các vectors V (đã được nhân với softmax output) cộng lại với nhau, tạo ra vector attention Z cho một từ. Lặp lại quá trình trên cho tất cả các từ ta được ma trận attention cho 1 câu.

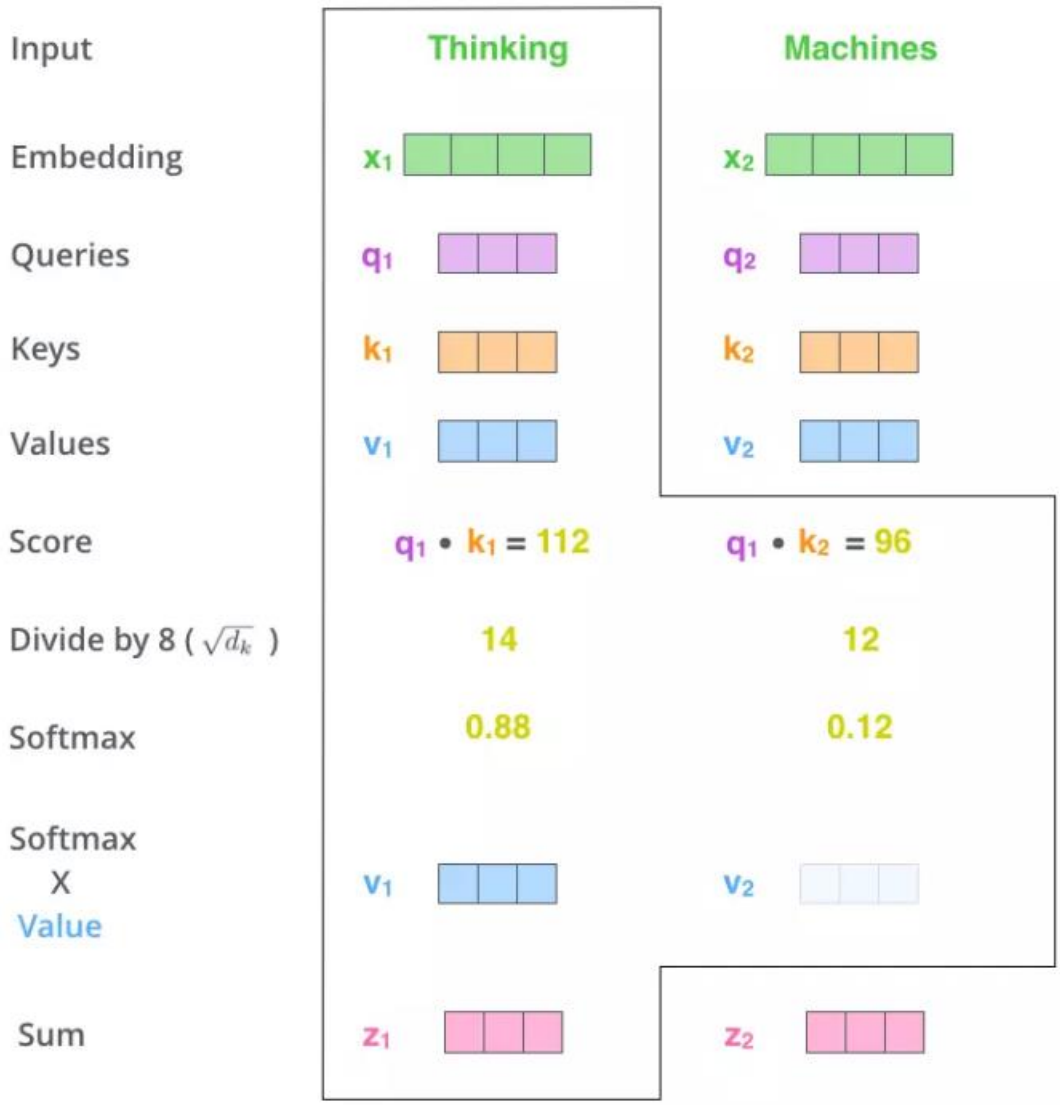

Vấn đề của Self-attention là attention của một từ sẽ luôn "chú ý" vào chính nó. Điều này hợp lý vì rõ ràng "nó" phải liên quan đến "nó" nhiều nhất. Nhưng chúng ta không mong muốn điều này, cái ta muốn là sự tương tác giữa các từ KHÁC NHAU trong câu. Multi-head attention là phiên bản nâng cấp hơn của Self-attention. Ý tưởng rất đơn giản là thay vì sử dụng 1 Self-attention (1 head) thì ta sử dụng nhiều Attention khác nhau (multi-head) và biết đâu mỗi Attention sẽ chú ý đến một phần khác nhau trong câu.

Vì mỗi "head" sẽ cho ra một ma trận attention riêng nên ta phải concatenate các ma trận này và nhân với ma trận trọng số W^O để ra một ma trận attention duy nhất (weighted sum). Và tất nhiên, ma trận trọng số này cũng được tune trong khi training.

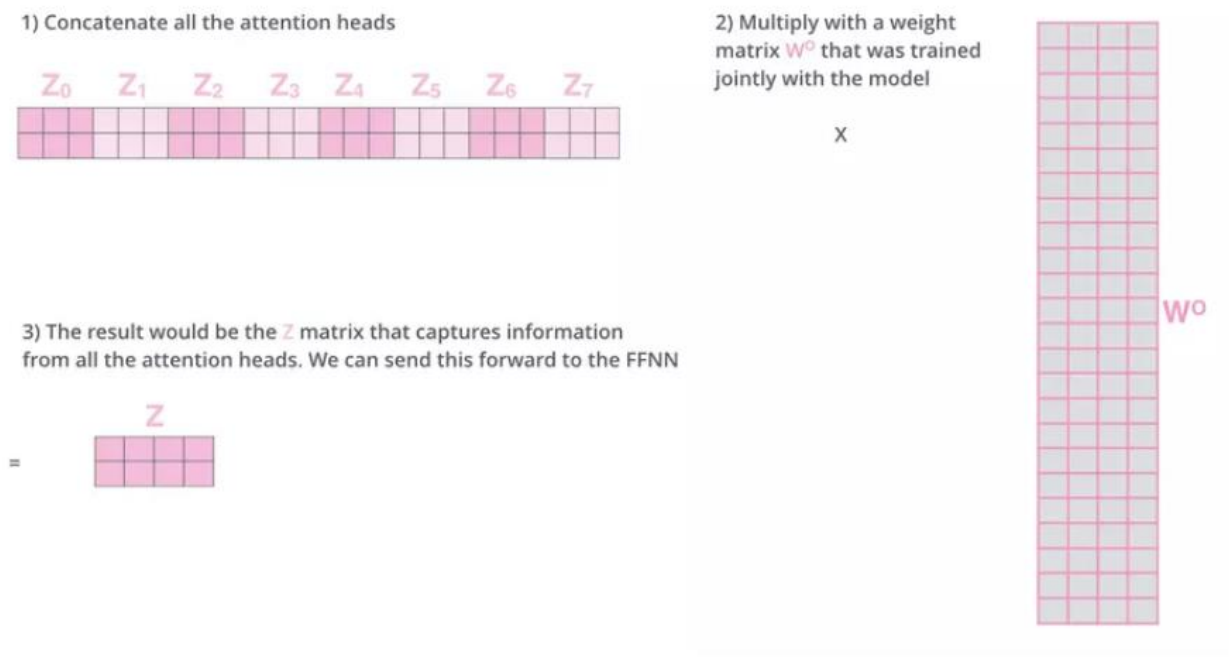

Sau khi được Normalize, các vectors z được đưa qua mạng fully connected trước khi đẩy qua Decoder. Vì các vectors này không phụ thuộc vào nhau nên ta có thể tận dụng được tính toán song song cho cả câu.

4. Decoder sử dụng GPT2

Sử dụng mô hình GPT2 như một text decoder

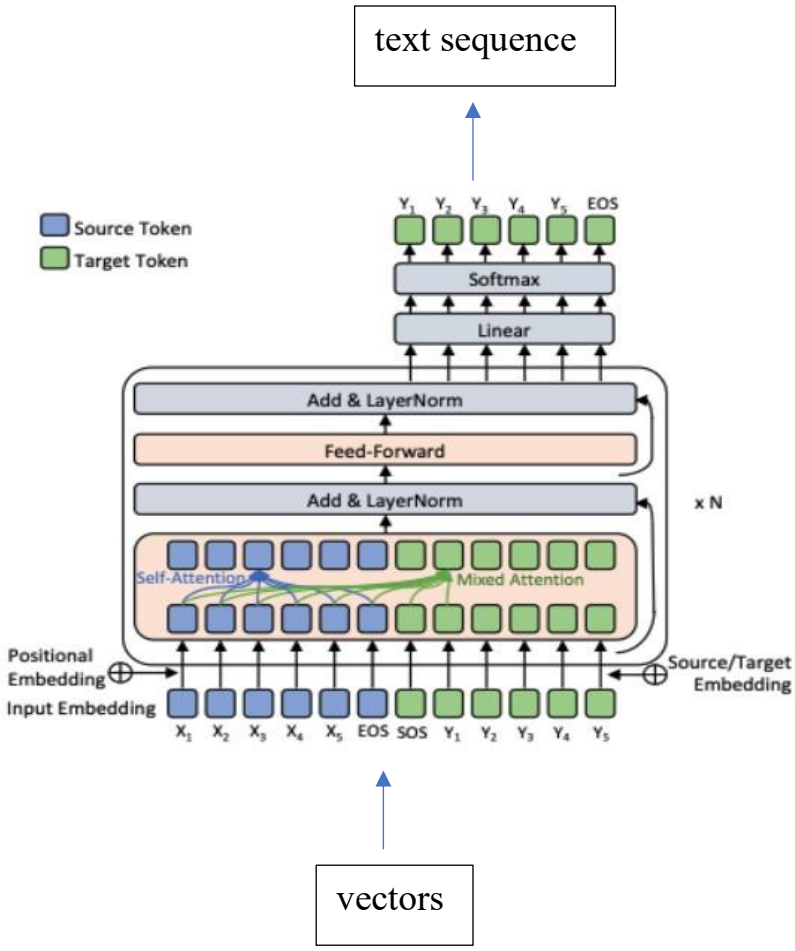

Input Embedding: đầu vào là các vector

Một từ khi ở những vị trí khác nhau trong câu có thể mang ý nghĩa khác nhau, đó là lý do transformer có thêm một phần Positional Encoding để bổ sung thêm thông tin về vị trí của 1 từ

5. Phương pháp đánh giá

Với một bức ảnh:

Gọi predicted_caption là câu mô tả ảnh được sinh bởi mô hình, truth_caption là câu mô tả ảnh đúng (được tạo bởi con người).

$$\text{recall} = \frac{predicted_caption \cap truth_caption}{Số\ lượng\ các\ từ\ trong\ truth_caption}$$

$$\text{precision} = \frac{predicted_caption \cap truth_caption}{Số\ lượng\ các\ từ\ trong\ prediced_caption}$$

F-Measure $=2 \cdot \frac{precision \cdot recall}{precision+recall}$

Với bài toán image captioning thì ưu tiên sử dụng độ đo recall. Vì precision và F-mesasure thường có giá nhỏ, khó để cải thiện các giá trị precision và F-mesasure.

Trong các mô hình image-captioning, độ đo recall còn được gọi là ROUGE (Recall-Orientes Understudy for Gisting Evaluation).

Ví dụ:

1-gram

predicted_output: the cat was found under the bed

truth_output: the cat was under the bed in my room

ROUGE1-recall = 6/9=0.67

2-gram:

predicted_output: the_cat, cat_was, was_found, found_under, under_the, the_bed

truth_output: the_cat, cat_was, was_under, under_the, the_bed, bed_in, in_my, my_room

ROUGE2-recall = 4/8 = 0.5

Khi đánh giá trên một tập test, lấy giá trị trung bình cộng của tất cả các recall của mỗi ảnh trong tập test.

6. Thử nghiệm

Thực hiện huấn luyện mô hình Image Captioning với mô hình pre-trained Vision Trainformer làm encoder + pre-trained language model là GPT2 làm decoder.

pre-trained Vision Trainformer được huấn luyện trên ImageNet-21k (một bộ dữ liệu gồm 14 triệu ảnh và 21.000 class)

pre-trained language model GPT2 được huấn luyện trên một tập chứa số lượng rất lớn văn bản tiếng Anh, được huấn luyện theo kiểu self-supervised, nghĩa là nó được huấn luyện ở trên dữ liệu thô, không được gán nhãn.

Bộ dữ liệu huấn luyện: sử dụng bộ dữ liệu Flickr 8k (bộ dữ liệu bao gồm 8000 bức ảnh, đi kèm với mỗi bức ảnh là 5 câu mô tả khác nhau cho nội dung của bức ảnh). Lấy 80% tập dữ liệu Flickr 8k để train và 20% còn lại để làm tập dữ liệu đánh giá (tập test).

https://www.kaggle.com/datasets/adityajn105/flickr8k

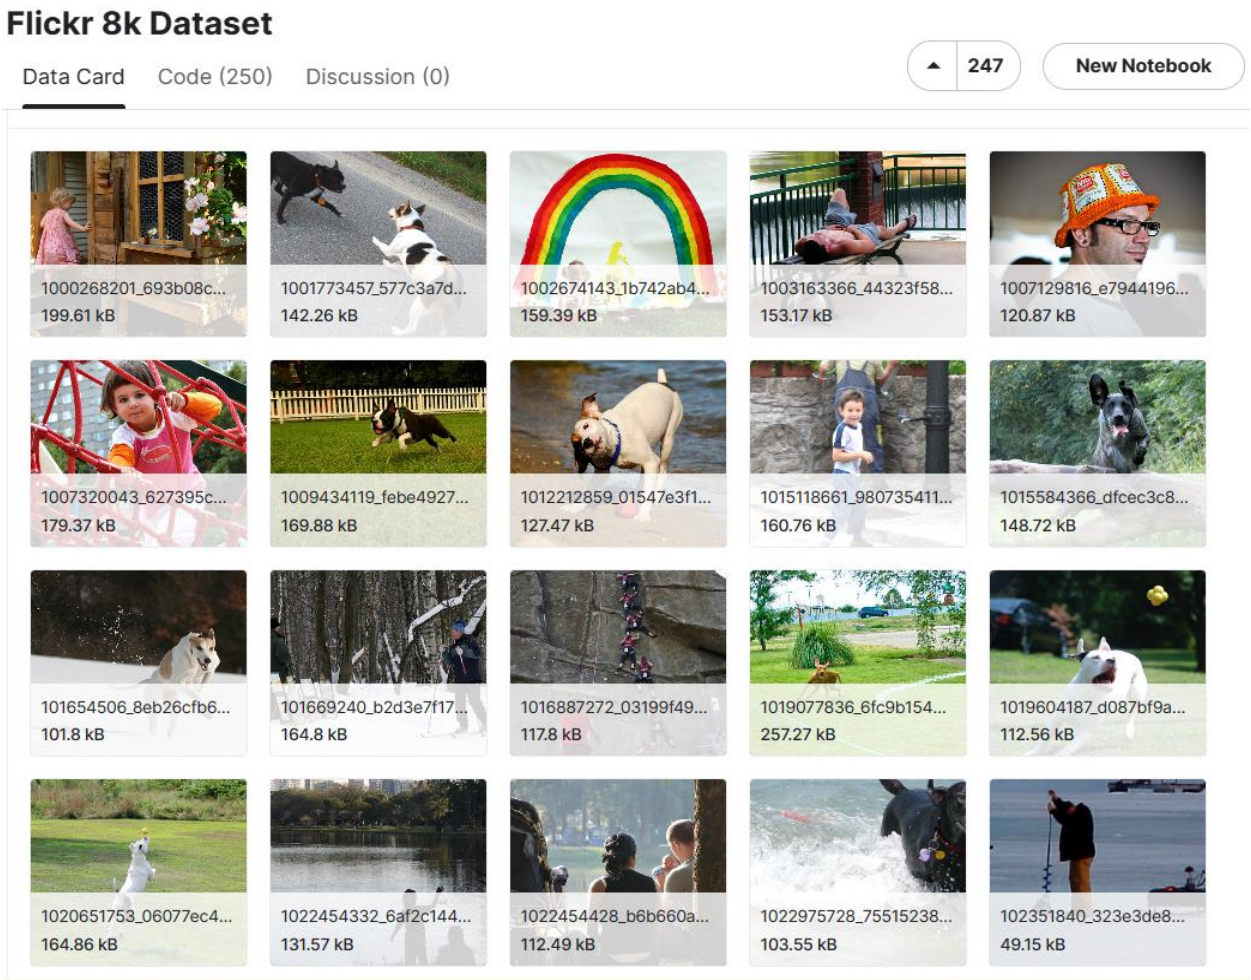

Sử dụng GPU P100 của Kaggle để huấn luyện mô hình, với thời gian huấn luyện là 7 tiếng.

Kết quả thử nghiệm:

[12138/12138 6:46:46, Epoch 3/3]

Epoch	Training Loss	Validation Loss	Rouge2 Precision	Rouge2 Recall	Rouge2 Fmeasure
1	2.622200	2.400070	0.030100	0.290300	0.053600
2	2.140000	2.232012	0.033600	0.308400	0.059700
3	1.795300	2.216035	0.034800	0.312200	0.061100

Tại epoch thứ 3, recall đạt 31.22%

Thử nghiệm trên một vài ảnh trên tập test:

Ảnh 1:

```
True caption:
A young male surfer wearing a yellow shirt rides a wave in the ocean on his white board .


Predicted caption:
<|endoftext|>A surfer in a black wetsuit is falling off his surfboard. Another surfer
```

Ảnh 2:

```
True caption:
a young man skateboarding on a street wearing a black and white striped shirt


Predicted caption:
<|endoftext|>A young man wearing a white shirt and black shorts walks down the street
```

Ảnh 3:

```
True caption:
Two balloon artists are standing and sitting on a dry dirt hill .


Predicted caption:
<|endoftext|>A black and white dog is standing in front of a pile of sand. A man is s
```

Ảnh 4:

```
True caption:
Two boys and a white dog stand in a park .


Predicted caption:
<|endoftext|>Two children play with a white dog in the grass... one is holding a Fris
```

Ảnh 5:

```
True caption:
Father and daughter are playing in a shallow area of a lake together .


Predicted caption:
<|endoftext|>A little girl and a little boy are running on the beach. the little girl
```

Ảnh 6:

```
True caption:
A girl in a white coat stands in the middle of a fountain and a boy in the background laughs
.


Predicted caption:
<|endoftext|>A girl in a pink jacket is standing in front of some water fountains. Sh
```

Ảnh 7;

```
True caption:
Man with purple sweater at the top of a skateboard ramp .


Predicted caption:
<|endoftext|>A skateboarder in a red shirt is doing a trick on a ramp... a boy in a b
```

Ảnh 8:

```
True caption:
A young boy eats food with chopsticks .


Predicted caption:
<|endoftext|>A young boy eats with chopsticks while sitting in a chair... he has his
```

Ảnh 9:

```
True caption:
A man in a checked shirt stands next to a large wooden bowl .


Predicted caption:
<|endoftext|>A man is standing in front of a large bowl of corn. A man is holding a l
```

Ảnh 10:

```
True caption:
A beautiful sunset with three people in a boat on the lake .


Predicted caption:
<|endoftext|>A man is rowing a boat on the water... with a sunset in the background..
```

Ảnh 11:

```
True caption:
The brown hair woman in the blue fleece sits beside a white hair woman .


Predicted caption:
<|endoftext|>A man and woman are conversing in a restaurant. The man is eating and th
```

Tài liệu tham khảo

The Illustrated Image Captioning using transformers:

https://ankur3107.github.io/blogs/the-illustrated-image-captioning-using-transformers

Model vit-gpt2-image-captioning:

https://huggingface.co/nlpconnect/vit-gpt2-image-captioning

Vision Transformer (ViT):

https://huggingface.co/docs/transformers/model_doc/vit

An Image is Worth 16x16 Words: Transformers for Image Recognition at Scale

https://arxiv.org/pdf/2010.11929.pdf

Model GPT-2:

https://huggingface.co/gpt2

Attention Is All You Need:

https://arxiv.org/pdf/1706.03762.pdf