# XỬ LÝ NGÔN NGỮ TỰ NHIÊN

**ĐỀ TÀI:**

## GÁN NHÃN TỪ LOẠI

Giảng viên hướng dẫn: **Nguyễn Trọng Chỉnh**

Thành viên:

- **Nguyễn Tam Điệp - 19521360**
- **Nguyễn Văn Thịnh - 19522286**

Lớp: **CS221.N11**

**Thành phố Hồ Chí Minh – Năm 2022**

# Mục Lục

Mục Lục ..... 1
I, Xác định bài toán ..... 2
II, Bộ dữ liệu sử dụng để đánh giá ..... 4
1, Sử dụng bộ dữ liệu NLTK corpus: ..... 4
2. Sử dụng bộ dữ liệu sưu tập được ..... 5
a, Cấu trúc bộ dữ liệu: ..... 5
b, Chuyển đổi bộ dữ liệu này về cấu trúc giống với cấu trúc của NLTK corpus ..... 6
III, Phương pháp Transformation Based Learning ..... 6
1, Thử nghiệm trên bộ dữ liệu NLTK corpus ..... 6
a, Pha học luật (huấn luyện) ..... 6
b, Pha áp dụng (dự đoán) ..... 7
c, Đánh giá ..... 8
2, Thử nghiệm trên bộ dữ liệu sưu tập được ..... 9
IV, Phương pháp Hidden Markov Model ..... 9
1, Thử nghiệm trên bộ dữ liệu NLTK corpus ..... 9
a, Smoothing ..... 9
b, Huấn luyện ..... 10
c, Dự đoán ..... 10
d, Đánh giá ..... 11
2, Thử nghiệm trên bộ dữ liệu sưu tập được ..... 12
V, Kết luận ..... 12

# I, Xác định bài toán

Bài toán gán nhãn từ loại:

Input:

- Là một tập hợp gồm nhiều câu, mỗi câu gồm các từ chưa được gán nhãn.

Output:

- Là một tập hợp các câu đã được gán nhãn từ loại
- Mỗi câu là một tập hợp các từ đã được gán nhãn
- Mỗi từ được gán nhãn là một bộ (word, tag), gán nhãn theo nhãn trong bộ nhãn từ loại Penn Treebank

*Bộ nhãn từ loại Penn Treebank:*

| Tag | Description | Example | Tag | Description | Example | Tag | Description | Example |
|---|---|---|---|---|---|---|---|---|
| CC | coordinating conjunction | *and, but, or* | PDT | predeterminer | *all, both* | VBP | verb non-3sg present | *eat* |
| CD | cardinal number | *one, two* | POS | possessive ending | *'s* | VBZ | verb 3sg pres | *eats* |
| DT | determiner | *a, the* | PRP | personal pronoun | *I, you, he* | WDT | wh-determ. | *which, that* |
| EX | existential 'there' | *there* | PRP$ | possess. pronoun | *your, one's* | WP | wh-pronoun | *what, who* |
| FW | foreign word | *mea culpa* | RB | adverb | *quickly* | WP$ | wh-possess. | *whose* |
| IN | preposition/ subordin-conj | *of, in, by* | RBR | comparative adverb | *faster* | WRB | wh-adverb | *how, where* |
| JJ | adjective | *yellow* | RBS | superlatv. adverb | *fastest* | $ | dollar sign | *$* |
| JJR | comparative adj | *bigger* | RP | particle | *up, off* | # | pound sign | *#* |
| JJS | superlative adj | *wildest* | SYM | symbol | *+,%, &* | " | left quote | ' or " |
| LS | list item marker | *1, 2, One* | TO | "to" | *to* | " | right quote | ' or " |
| MD | modal | *can, should* | UH | interjection | *ah, oops* | ( | left paren | [, (, {, < |
| NN | sing or mass noun | *llama* | VB | verb base form | *eat* | ) | right paren | ], ), }, > |
| NNS | noun, plural | *llamas* | VBD | verb past tense | *ate* | , | comma | , |
| NNP | proper noun, sing. | *IBM* | VBG | verb gerund | *eating* | . | sent-end punc | . ! ? |
| NNPS | proper noun, plu. | *Carolinas* | VBN | verb past part. | *eaten* | : | sent-mid punc | : ; ... – - |

Ví dụ:

Input:

```
[
[('I', 'am', 'sure', 'you', 'will', 'find', 'true', 'love', '.']
['My', 'cat', 'is', 'so', 'pretty' '.']
['The', 'horror', 'film', 'is', 'my', 'favourite', 'film', 'genre' '.']
]
```

Output:

```
[
[('I', 'PRP'), ('am', 'VBP'), ('sure', 'JJ'), ('you', 'PRP'), ('will',
'MD'), ('find', 'VB'), ('true', 'JJ'), ('love', 'NN'), ('.', '.')]
[('My', 'PRP$'), ('cat', 'NN'), ('is', 'VBZ'), ('so', 'RB'), ('pretty',
'JJ'), ('.', '.')]
[('The', 'DT'), ('horror', 'NN'), ('film', 'NN'), ('is', 'VBZ'), ('my',
'PRP$'), ('favourite', 'JJ'), ('film', 'NN'), ('genre', 'NN'), ('.', '.')]
]
```

Có 2 phương pháp gán nhãn từ loại được nhóm em sử dụng:

- Tranformation Base Learning
- Hidden Markov Model

## II, Bộ dữ liệu sử dụng để đánh giá

1, Sử dụng bộ dữ liệu NLTK corpus:

```
nltk.download('treebank')
data_treebank = treebank.tagged_sents()
```

Cấu trúc của tập *data_treebank* :

Là môt mảng 2 chiều, mỗi hàng là một mảng chứa các phần tử là bộ *(word, pos)* (với *word* là từ trong một câu và *pos* là nhãn từ loại tương ứng của từ đó)

```
[
[('Pierre', 'NNP'), ('Vinken', 'NNP'), (',', ','), ... , ('.', '.')],
[('Mr.', 'NNP'), ('Vinken', 'NNP'), ('is', 'VBZ'), ... , ('.', '.')],
[('Rudolph', 'NNP'), ('Agnew', 'NNP'), (',', ','), ... , ('.', '.')],
[('A', 'DT'), ('form', 'NN'), ('of', 'IN'), ... , ('.', '.')]
[('The', 'DT'), ('asbestos', 'NN'), ('fiber', 'NN'), ... , ('.',
'.')],
[...]
]
```

Số câu trong tập dữ liệu này: 3914

Số từ trong tập dữ liệu này: 100676 từ tiếng Anh

```
print('so cau: ', len(data_treebank))

#dem so tu
dem = 0
for s in data_treebank:
  dem += len(s)
print('so tu: ', dem)

```

```
so cau:  3914
so tu:  100676
```

2. Sử dụng bộ dữ liệu sưu tập được

a, Cấu trúc bộ dữ liệu:

- Tập train: chứa 8936 câu, 211727 từ tiếng Anh đã được gán nhãn theo nhãn trong bộ nhãn từ loại Penn Treebank.
- Tập test: chứa 2012 câu, 47377 từ tiếng Anh đã được gán nhãn theo nhãn trong bộ nhãn từ loại Penn Treebank.

Mỗi từ nằm trên một dòng:

Tập train:

```
Confidence NN B-NP
in IN B-PP
the DT B-NP
pound NN I-NP
is VBZ B-VP
...
```

Tập test:

```
Rockwell NNP B-NP
International NNP I-NP
Corp. NNP I-NP
's POS B-NP
Tulsa NNP I-NP
...
```

Nguồn Download bộ dữ liệu:

Download tập train:

https://www.cnts.ua.ac.be/conll2000/chunking/train.txt.gz

Download tập test:

https://www.cnts.ua.ac.be/conll2000/chunking/test.txt.gz

(Chi tiết về bộ dữ liệu này tại: https://www.cnts.ua.ac.be/conll2000/chunking/)

b, Chuyển đổi bộ dữ liệu này về cấu trúc giống với cấu trúc của NLTK corpus
Chuyển đổi thành môt mảng 2 chiều, mỗi hàng là một mảng chứa các phần tử là bộ *(word, pos)* (với *word* là từ trong một câu và *pos* là nhãn từ loại tương ứng của từ đó)

Tập train:

```
[
[('Confidence', 'NN'), ('in', 'IN'), ('the', 'DT'), ... , ('.', '.')],
[('Chancellor', 'NNP'), ('of', 'IN'), ('the', 'DT'), ... , ('.', '.')],
[('But', 'CC'), ('analysts', 'NNS'), ('reckon', 'VBP'), ... , ('.', '.')],
...
]
```

Tập test:

```
[
[('Rockwell', 'NNP'), ('International', 'NNP'), ('Corp.', 'NNP'), ... ,
('.', '.')],
[('Rockwell', 'NNP'), ('said', 'VBD'), ('the', 'DT'), ... , ('.', '.')],
[('These', 'DT'), ('include', 'VBP'), (',', ','), ... , ('.', '.')],
...
]
```

## III, Phương pháp Transformation Based Learning

1, Thử nghiệm trên bộ dữ liệu NLTK corpus

a, Pha học luật (huấn luyện)

B1: Gán nhãn từ loại ban đầu cho mỗi từ trong tập train theo most frequent class:

Với mỗi từ trong tập train, chọn nhãn có tần số xuất hiện nhiều nhất và gán nhãn ban đầu cho nó.

B2: Chọn Template

- Là dạng của luật, được xác định để TBL học các luật theo dạng này
- Template sử dụng 2 dạng đặc trưng là từ và nhãn từ loại
- Khai báo:

```
from nltk.tbl import Template
from nltk.tag.brill import Word, Pos
```

- Tạo một template: t = Template(Đặc_Trưng_1, Đặc_Trưng_2, …).
  Nhóm em sử dụng Template xét từ đứng trước và nhãn từ loại đứng trước
  ```
  t = Template(Word([-1]), Pos([-1]))
  ```

B3: Sử dụng thư viện NLTK:

```
from nltk.tag.brill_trainer import BrillTaggerTrainer
```

trainer = BrillTaggerTrainer(init_tagger, templates)

tagger = trainer.train(train_data) Trong đó:

- init_tagger là một bộ gán nhãn từ loại ban đầu
- templates là một tập hợp các template
- train_data là ngữ liệu gán nhãn

```
init_tagger = INITIALIZE_WITH_MOST_LIKELY_TAG(train_set)
t = Template(Word([-1]), Pos([-1]))
templates = [t]
TBLtrainer = BrillTaggerTrainer(init_tagger, templates)
TBLtagger = TBLtrainer.train(train_set, max_rules=100000, min_score=-100000)
```

b, Pha áp dụng (dự đoán)

Sử dụng hàm tag của đối tượng chứa mô hình đã huấn luyện:

pos = tagger.tag(Danh_Sách_Từ_Chưa_gán_Nhãn)

```
Data = [
['I', 'am', 'sure', 'you', 'will', 'find', 'true', 'love', '.'],
['My', 'cat', 'is', 'so', 'pretty', '.'],
['The', 'horror', 'film', 'is', 'my', 'favourite', 'film', 'genre', '.']
]
```

```
for sentence in Data:
  pos = TBLtagger.tag(sentence)
  print(pos)
```

Kết quả:

```
[('I', 'PRP'), ('am', 'VBP'), ('sure', 'JJ'), ('you', 'PRP'), ('will',
'MD'), ('find', 'VB'), ('true', 'JJ'), ('love', '??'), ('.', '.')]
[('My', 'PRP$'), ('cat', '??'), ('is', 'VBZ'), ('so', 'RB'), ('pretty',
'RB'), ('.', '.')]
[('The', 'DT'), ('horror', '??'), ('film', 'NN'), ('is', 'VBZ'), ('my',
'PRP$'), ('favourite', '??'), ('film', 'NN'), ('genre', '??'), ('.', '.')]
```

Nhãn '??' để gán cho những từ không xuất hiện trong tập train dẫn đến không thể xác định được từ loại của nó.

c, Đánh giá

***PHƯƠNG PHÁP***

- Huấn luyện mô hình với dữ liệu train
- Tách dữ liệu test thành hai phần, phần chỉ chứa từ Text và phần chỉ chứa nhãn từ loại Pos tương ứng với Text.
- Dùng mô hình đã được huấn luyện để dự đoán nhãn PPos từ dữ liệu Text
- So sánh PPos và Pos

***ĐỘ ĐO***

- Sử dụng độ chính xác Accuracy theo công thức: Acc = n/N Trong đó:
- n là số tag của PPos trùng vớp Pos
- N là số tag của PPos (hoặc Pos)

Với bộ dữ liệu NLTK corpus, nhóm em sử dụng tập NLTK corpus làm tập train, cũng đồng thời dùng nó làm tập test

Kết quả đánh giá: Phương pháp TBL train và đánh giá trên tập NTLK corpus theo độ đo Accuracy đạt độ chính xác 98.23%

```
print('TBL Acc: ')
print(TBLtagger.accuracy(test_set))
```

```
TBL Acc:
0.9823592514601295
```

2, Thử nghiệm trên bộ dữ liệu sưu tập được

- Huấn luyện trên tập train và đánh giá trên tập test
- Sử dụng độ đo Accuracy
- Kết quả đánh giá trên tập test: độ chính xác = 90.74%

```
print('TBL Acc: ')
print(TBLtagger.accuracy(test_set))
```

```
TBL Acc:
0.9074445405998691
```

# IV, Phương pháp Hidden Markov Model

1, Thử nghiệm trên bộ dữ liệu NLTK corpus

a, Smoothing

- Là kỹ thuật ước lượng xác suất cho những trường hợp hiếm gặp hoặc không xuất hiện trong bộ ngữ liệu huấn luyện.
- Sử dụng một số phương pháp như Laplace, Witten Bell

```
from nltk.probability import LaplaceProbDist, WittenBellProbDist
```

b, Huấn luyện

- Khai báo sử dụng lớp HiddenMarkovModelTrainer

```
from nltk.tag.hmm import HiddenMarkovModelTrainer
```

- Tạo đối tượng trainer:

```
HMMtrainer = HiddenMarkovModelTrainer()
```

- Huấn luyện mô hình tagger:

tagger = trainer.train_supervised(train_data, estimator=Phương_Pháp_Smoothing)

```
HMMtagger = HMMtrainer.train_supervised(train_set, estimator=LaplaceProbDist)
```

(Sử dụng phương pháp Smoothing Laplace)

c, Dự đoán

- Sử dụng hàm tag của đối tượng chứa mô hình đã huấn luyện:

pos = tagger.tag(Danh_Sách_Từ_Chưa_gán_Nhãn)

```
Data = [
['I', 'am', 'sure', 'you', 'will', 'find', 'true', 'love', '.'],
['My', 'cat', 'is', 'so', 'pretty', '.'],
['The', 'horror', 'film', 'is', 'my', 'favourite', 'film', 'genre', '.']
]
```

```
for sentence in Data:
    pos = HMMtagger.tag(sentence)
    print(pos)
```

Kết quả:

```
[('I', 'PRP'), ('am', 'MD'), ('sure', 'VB'), ('you', 'PRP'), ('will',
'MD'), ('find', 'VB'), ('true', 'JJ'), ('love', 'NN'), ('.', '.')]
[('My', '``'), ('cat', 'PRP'), ('is', 'VBZ'), ('so', 'RB'), ('pretty',
'RB'), ('.', '.')]
[('The', 'DT'), ('horror', 'JJ'), ('film', 'NN'), ('is', 'VBZ'), ('my',
'PRP$'), ('favourite', 'JJ'), ('film', 'NN'), ('genre', 'NNS'), ('.', '.')]
```

d, Đánh giá

***PHƯƠNG PHÁP***

- Huấn luyện mô hình với dữ liệu train
- Tách dữ liệu test thành hai phần, phần chỉ chứa từ Text và phần chỉ chứa nhãn từ loại Pos tương ứng với Text.
- Dùng mô hình đã được huấn luyện để dự đoán nhãn PPos từ dữ liệu Text
- So sánh PPos và Pos

***ĐỘ ĐO***

- Sử dụng độ chính xác Accuracy theo công thức: Acc = n/N Trong đó:
- n là số tag của PPos trùng vớp Pos
- N là số tag của PPos (hoặc Pos)

Với bộ dữ liệu NLTK corpus, nhóm em sử dụng tập NLTK corpus làm tập train, cũng đồng thời dùng nó làm tập test

Kết quả đánh giá: Phương pháp Hidden Markov Model train và đánh giá trên tập NTLK corpus theo độ đo Accuracy đạt độ chính xác 89.32%

```
print('HMM Acc: ')
print(HMMtagger.accuracy(test_set))
```

```
HMM Acc:
0.8932218204934642
```

2, Thử nghiệm trên bộ dữ liệu sưu tập được

- Huấn luyện trên tập train và đánh giá trên tập test
- Sử dụng độ đo Accuracy
- Kết quả đánh giá trên tập test: độ chính xác = 89.2%

```
print('HMM Acc: ')
print(HMMtagger.accuracy(test_set))
```

```
HMM Acc:
0.8920151128184562
```

# V, Kết luận

Phương pháp Transformation Based Learning có độ chính xác cao hơn phương pháp Hidden Markov Model. Tuy nhiên, nhược điểm của phương pháp Transformation Based Learning là nó không thể gán nhãn được một từ nếu từ đó không xuất hiện trong tập dữ liệu huấn luyện. Trong khi đó, phương pháp Hidden Markov Model có thể gán nhãn cho những từ chưa từng xuất hiện trong tập huấn luyện.